

Конспект по статистике

Метод максимального правдоподобия и доверительные интервалы

Лекция от 10.04.2026

Основные темы лекции

1. Метод максимального правдоподобия.
2. Функция правдоподобия.
3. Логарифм функции правдоподобия.
4. Почему максимум правдоподобия можно искать через максимум логарифма.
5. Оценка параметра дискретного равномерного распределения.
6. Оценка параметра распределения Бернулли.
7. Оценка параметра геометрического распределения.
8. Оценка вектора вероятностей категориального распределения.
9. Смещение оценки.
10. Среднеквадратичная ошибка MSE.
11. Идея сравнения оценок через MSE.
12. Доверительный интервал.
13. Уровень доверия.
14. Типовая схема построения доверительного интервала через квантили.
15. Проблема неизвестного распределения оценки.
16. Bootstrap как способ приближать распределение оценки.
17. Bootstrap-доверительный интервал.

Содержание

1	Общий контекст	4
2	Параметрическая статистическая модель	4
3	Оценка параметра	5

4	Метод максимального правдоподобия	5
5	Функция правдоподобия	5
6	Логарифм функции правдоподобия	6
7	Почему можно брать логарифм	6
8	Типичный алгоритм MLE	6
9	Пример 1: дискретное равномерное распределение	7
10	Функция правдоподобия для дискретного равномерного распределения	7
11	Почему появляется максимум выборки	8
12	Числовой пример	8
13	Пример 2: распределение Бернулли	9
14	Функция правдоподобия для Бернулли	9
15	Производная логарифма правдоподобия	9
16	MLE для Бернулли	10
17	Проверка максимума для Бернулли	10
18	Пример 3: геометрическое распределение	11
19	Функция правдоподобия для геометрического распределения	11
20	Производная для геометрического распределения	11
21	Замечание о другой версии геометрического распределения	12
22	Пример 4: категориальное распределение	13
23	Обозначения для частот	13
24	Функция правдоподобия для категориального распределения	13
25	MLE для категориального распределения	14
26	Почему возникает условный экстремум	14
27	Смещение оценки	14
28	Среднеквадратичная ошибка	15
29	Как сравнивать оценки через MSE	15
30	От точечной оценки к интервальной	15
31	Доверительный интервал	16

32 Типичные уровни доверия	16
33 Как понимать доверительный интервал	16
34 Длина доверительного интервала	17
35 Типовая схема построения доверительного интервала	17
36 Вывод формулы интервала	17
37 Что такое квантиль	18
38 Проблема неизвестного распределения	18
39 Bootstrap: основная идея	19
40 Bootstrap-выборки	19
41 Bootstrap-аппроксимация распределения	19
42 Bootstrap-доверительный интервал	20
43 Пример: Бернулли и bootstrap	20
44 Что происходит при увеличении объёма выборки	21
45 Что важно уметь объяснить на ответе	21
46 Мини-шпаргалка	22
47 Главное, что нужно запомнить	24

1 Общий контекст

Лекция состоит из двух больших частей.

Первая часть:

метод максимального правдоподобия

или по-английски:

maximum likelihood estimation, MLE.

Здесь речь идёт о точечном оценивании параметров распределения.

Вторая часть:

доверительные интервалы

то есть интервальное оценивание параметров.

Главный переход лекции такой:

сначала оцениваем параметр одним числом, затем хотим оценить его интервалом.

2 Параметрическая статистическая модель

Пусть есть выборка

$$X_1, \dots, X_n.$$

Предположим, что распределение каждого X_i известно с точностью до параметра θ .

Например:

$$X_i \sim \text{Bern}(p),$$

где неизвестен параметр p .

Или:

$$X_i \sim \text{Geom}(p),$$

где неизвестен параметр p .

Или:

$$X_i \sim \text{Unif}\{1, \dots, m\},$$

где неизвестна правая граница m .

Задача статистики:

по наблюдаемым данным оценить неизвестный параметр.

3 Оценка параметра

Определение 1. Оценкой параметра θ называется функция от выборки

$$\hat{\theta} = \hat{\theta}(X_1, \dots, X_n).$$

Важно:

$\hat{\theta}$ — случайная величина, потому что она зависит от случайной выборки.

После того как выборка уже наблюдена, оценка принимает конкретное числовое значение.

Например, если

$$X_1, \dots, X_n \sim \text{Bern}(p),$$

то естественная оценка параметра p :

$$\hat{p} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

4 Метод максимального правдоподобия

Определение 2. Метод максимального правдоподобия — это способ выбрать такое значение параметра, при котором наблюдаемая выборка имеет максимальную вероятность.

Идея:

выбираем тот параметр, при котором данные выглядят наиболее правдоподобными.

Если параметр обозначается через θ , то оценка максимального правдоподобия:

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} L(\theta).$$

Здесь $L(\theta)$ — функция правдоподобия.

5 Функция правдоподобия

Пусть $X_1, \dots, X_n$ независимы и имеют функцию вероятности или плотность

$$f_{\theta}(x).$$

Тогда совместная вероятность или плотность выборки:

$$f_{\theta}(x_1, \dots, x_n) = \prod_{i=1}^n f_{\theta}(x_i).$$

Определение 3. Функцией правдоподобия называется эта же совместная вероятность, но рассматриваемая как функция параметра θ при фиксированных наблюдениях $x_1, \dots, x_n$:

$$L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n f_{\theta}(x_i).$$

Обычно пишут кратко:

$$L(\theta).$$

Замечание 1. Разница тонкая: вероятность рассматривает данные как случайные, а параметр как фиксированный. Правдоподобие рассматривает данные как уже зафиксированные, а параметр как переменную.

6 Логарифм функции правдоподобия

Часто вместо $L(\theta)$ максимизируют логарифм:

$$\ell(\theta) = \ln L(\theta).$$

Это удобно, потому что:

$$\ln \prod_{i=1}^n f_{\theta}(x_i) = \sum_{i=1}^n \ln f_{\theta}(x_i).$$

То есть произведение превращается в сумму.

7 Почему можно брать логарифм

Логарифм строго возрастает:

$$a > b \iff \ln a > \ln b.$$

Поэтому точки максимума у $L(\theta)$ и у $\ell(\theta)$ совпадают:

$$\boxed{\arg \max_{\theta} L(\theta) = \arg \max_{\theta} \ln L(\theta).}$$

Но производные логарифма обычно считать проще.

8 Типичный алгоритм MLE

1. Записать функцию вероятности или плотность $f_{\theta}(x)$.
2. Записать функцию правдоподобия:

$$L(\theta) = \prod_{i=1}^n f_{\theta}(x_i).$$

3. Взять логарифм:

$$\ell(\theta) = \ln L(\theta).$$

4. Найти производную по параметру:

$$\ell'(\theta).$$

5. Решить уравнение:

$$\ell'(\theta) = 0.$$

6. Проверить, что найденная точка действительно даёт максимум.

Замечание 2. Иногда максимум достигается на границе области параметров. Тогда одного уравнения $\ell'(\theta) = 0$ недостаточно. Примером является дискретное равномерное распределение на $\{1, \dots, m\}$.

9 Пример 1: дискретное равномерное распределение

Пусть

$$X_1, \dots, X_n$$

— выборка из дискретного равномерного распределения на множестве

$$\{1, 2, \dots, m\}.$$

То есть:

$$\mathbb{P}(X = k) = \frac{1}{m}, \quad k = 1, \dots, m.$$

Неизвестный параметр:

$$m.$$

Нужно оценить m .

10 Функция правдоподобия для дискретного равномерного распределения

Для одного наблюдения:

$$\mathbb{P}(X_i = x_i) = \begin{cases} \frac{1}{m}, & x_i \in \{1, \dots, m\}, \\ 0, & \text{иначе.} \end{cases}$$

Для всей выборки:

$$L(m) = \prod_{i=1}^n \frac{1}{m} \mathbf{1}\{x_i \in \{1, \dots, m\}\}.$$

Это можно записать так:

$$L(m) = \frac{1}{m^n} \mathbf{1}\{m \geq x_{(n)}\},$$

где

$$x_{(n)} = \max\{x_1, \dots, x_n\}.$$

11 Почему появляется максимум выборки

Если

$$m < x_{(n)},$$

то хотя бы одно наблюдение больше m .

Тогда такая выборка невозможна при данном m , и:

$$L(m) = 0.$$

Чтобы правдоподобие не занулялось, нужно:

$$m \geq x_{(n)}.$$

С другой стороны, при $m \geq x_{(n)}$:

$$L(m) = \frac{1}{m^n}.$$

Эта величина убывает при росте m .

Поэтому среди всех допустимых m нужно взять минимальное:

$$\hat{m}_{\text{MLE}} = x_{(n)} = \max\{X_1, \dots, X_n\}.$$

12 Числовой пример

Пусть наблюдения:

$$1, 3, 10, 15, 20, 14.$$

Тогда:

$$x_{(n)} = 20.$$

Если взять $m = 19$, то наблюдение 20 невозможно, значит:

$$L(19) = 0.$$

Если взять $m = 20$, все наблюдения допустимы.

Если взять $m = 21$, все наблюдения тоже допустимы, но:

$$\frac{1}{21^n} < \frac{1}{20^n}.$$

Поэтому MLE:

$$\hat{m}_{\text{MLE}} = 20.$$

13 Пример 2: распределение Бернулли

Пусть

$$X_1, \dots, X_n \sim \text{Bern}(p).$$

То есть:

$$X_i \in \{0, 1\}.$$

Функция вероятности:

$$\mathbb{P}(X = x) = p^x(1-p)^{1-x}, \quad x \in \{0, 1\}.$$

Если $x = 1$, получаем p .

Если $x = 0$, получаем $1 - p$.

14 Функция правдоподобия для Бернулли

Функция правдоподобия:

$$L(p) = \prod_{k=1}^n p^{x_k}(1-p)^{1-x_k}.$$

Логарифм:

$$\ell(p) = \ln L(p) = \sum_{k=1}^n (x_k \ln p + (1-x_k) \ln(1-p)).$$

15 Производная логарифма правдоподобия

Дифференцируем по p :

$$\ell'(p) = \sum_{k=1}^n \left(\frac{x_k}{p} - \frac{1-x_k}{1-p} \right).$$

Приведём к общему знаменателю:

$$\ell'(p) = \sum_{k=1}^n \frac{x_k(1-p) - p(1-x_k)}{p(1-p)}.$$

В числителе:

$$x_k(1-p) - p(1-x_k) = x_k - x_k p - p + p x_k = x_k - p.$$

Значит:

$$\begin{aligned} \ell'(p) &= \frac{1}{p(1-p)} \sum_{k=1}^n (x_k - p). \\ &= \frac{1}{p(1-p)} \left(\sum_{k=1}^n x_k - np \right). \end{aligned}$$

16 MLE для Бернулли

Приравниваем производную к нулю:

$$\sum_{k=1}^n x_k - np = 0.$$

Отсюда:

$$p = \frac{1}{n} \sum_{k=1}^n x_k.$$

Значит:

$$\boxed{\hat{p}_{\text{MLE}} = \bar{X}.$$

То есть оценка максимального правдоподобия параметра Бернулли — это доля единиц в выборке.

17 Проверка максимума для Бернулли

Из формулы производной:

$$\ell'(p) = \frac{n(\bar{x} - p)}{p(1 - p)}.$$

Так как

$$p(1 - p) > 0$$

при

$$0 < p < 1,$$

знак производной определяется разностью

$$\bar{x} - p.$$

Если

$$p < \bar{x},$$

то

$$\ell'(p) > 0,$$

то есть функция возрастает.

Если

$$p > \bar{x},$$

то

$$\ell'(p) < 0,$$

то есть функция убывает.

Следовательно, в точке

$$p = \bar{x}$$

достигается максимум.

18 Пример 3: геометрическое распределение

Пусть

$$X_1, \dots, X_n \sim \text{Geom}(p).$$

На лекции использовалась версия геометрического распределения, где X — число неудач до первого успеха:

$$X \in \{0, 1, 2, \dots\}.$$

Тогда:

$$\mathbb{P}(X = x) = (1 - p)^x p.$$

19 Функция правдоподобия для геометрического распределения

Функция правдоподобия:

$$L(p) = \prod_{k=1}^n (1 - p)^{x_k} p.$$

Логарифм:

$$\ell(p) = \sum_{k=1}^n (x_k \ln(1 - p) + \ln p).$$

То есть:

$$\ell(p) = \left(\sum_{k=1}^n x_k \right) \ln(1 - p) + n \ln p.$$

20 Производная для геометрического распределения

Дифференцируем:

$$\ell'(p) = -\frac{\sum_{k=1}^n x_k}{1 - p} + \frac{n}{p}.$$

Приравниваем к нулю:

$$-\frac{\sum_{k=1}^n x_k}{1 - p} + \frac{n}{p} = 0.$$

Переносим:

$$\frac{n}{p} = \frac{\sum_{k=1}^n x_k}{1-p}.$$

Перемножаем крест-накрест:

$$n(1-p) = p \sum_{k=1}^n x_k.$$

$$n - np = p \sum_{k=1}^n x_k.$$

$$n = p \left(n + \sum_{k=1}^n x_k \right).$$

Значит:

$$p = \frac{n}{n + \sum_{k=1}^n x_k}.$$

Так как

$$\overline{X} = \frac{1}{n} \sum_{k=1}^n x_k,$$

получаем:

$$\boxed{\hat{p}_{\text{MLE}} = \frac{1}{1 + \overline{X}}}.$$

21 Замечание о другой версии геометрического распределения

Если используется другая версия геометрического распределения, где X — номер первого успеха:

$$X \in \{1, 2, \dots\},$$

то функция вероятности:

$$\mathbb{P}(X = x) = (1-p)^{x-1}p.$$

В этой версии MLE получается:

$$\hat{p}_{\text{MLE}} = \frac{1}{\overline{X}}.$$

Поэтому в задачах нужно внимательно смотреть, какая версия геометрического распределения используется.

разные договорённости о $\text{Geom}(p)$ дают разные формулы MLE.

22 Пример 4: категориальное распределение

Пусть случайная величина принимает значения

$$1, 2, \dots, m.$$

Вероятности:

$$\mathbb{P}(X = j) = p_j, \quad j = 1, \dots, m.$$

Параметр — вектор:

$$p = (p_1, \dots, p_m).$$

Ограничения:

$$p_j \geq 0, \quad \sum_{j=1}^m p_j = 1.$$

23 Обозначения для частот

Пусть

$$\nu_j$$

— количество наблюдений, равных j :

$$\nu_j = \#\{k : X_k = j\}.$$

Тогда:

$$\sum_{j=1}^m \nu_j = n.$$

24 Функция правдоподобия для категориального распределения

Вероятность всей выборки:

$$L(p) = p_1^{\nu_1} p_2^{\nu_2} \cdots p_m^{\nu_m}.$$

То есть:

$$L(p) = \prod_{j=1}^m p_j^{\nu_j}.$$

Логарифм:

$$\ell(p) = \sum_{j=1}^m \nu_j \ln p_j.$$

Нужно максимизировать $\ell(p)$ при ограничении:

$$\sum_{j=1}^m p_j = 1.$$

25 MLE для категориального распределения

Итоговая оценка:

$$\hat{p}_j = \frac{\nu_j}{n}.$$

То есть вероятность каждого значения оценивается его относительной частотой в выборке.

Смысл:

MLE для категориального распределения совпадает с эмпирическими частотами.

26 Почему возникает условный экстремум

Здесь нельзя независимо оптимизировать все p_j , потому что они связаны условием:

$$p_1 + \dots + p_m = 1.$$

Формально можно использовать метод множителей Лагранжа.

Но можно также выразить один параметр через остальные:

$$p_m = 1 - \sum_{j=1}^{m-1} p_j.$$

После этого получится задача оптимизации по $m - 1$ переменным.

Результат всё равно:

$$\hat{p}_j = \frac{\nu_j}{n}.$$

27 Смещение оценки

Определение 4. Смещением оценки $\hat{\theta}$ называется разность

$$\text{Bias}(\hat{\theta}) = \mathbb{E}\hat{\theta} - \theta.$$

Если:

$$\mathbb{E}\hat{\theta} = \theta,$$

то оценка называется несмещённой.

$$\text{Bias}(\hat{\theta}) = 0 \iff \hat{\theta} \text{ несмещённая.}$$

28 Среднеквадратичная ошибка

Определение 5. Среднеквадратичная ошибка оценки $\hat{\theta}$ определяется как

$$\text{MSE}(\hat{\theta}) = \mathbb{E}(\hat{\theta} - \theta)^2.$$

Если параметр векторный, используют норму:

$$\text{MSE}(\hat{\theta}) = \mathbb{E} \left\| \hat{\theta} - \theta \right\|^2.$$

Например, для вектора вероятностей:

$$\|\hat{p} - p\|^2 = \sum_{j=1}^m (\hat{p}_j - p_j)^2.$$

29 Как сравнивать оценки через MSE

Если есть две оценки одного и того же параметра:

$$\hat{\theta}_1 \quad \text{и} \quad \hat{\theta}_2,$$

то можно сказать, что первая лучше второй по MSE, если:

$$\text{MSE}(\hat{\theta}_1) \leq \text{MSE}(\hat{\theta}_2).$$

На лекции было отмечено:

при некоторых условиях оценки максимального правдоподобия обладают хорошими асимптотическими свойствами, в частности могут быть эффективными по MSE.

Подробно это обычно изучается позже.

30 От точечной оценки к интервальной

До этого мы оценивали параметр одним числом:

$$\hat{\theta}.$$

Но одно число не показывает степень неопределённости.

Например, если:

$$\hat{p} = 0.4875,$$

то непонятно, насколько точна эта оценка.

Поэтому вводят интервальные оценки.

Идея:

вместо одного числа дать интервал, который с большой вероятностью накрывает параметр.

31 Доверительный интервал

Определение 6. Пусть $X = (X_1, \dots, X_n)$ — выборка из распределения с параметром θ . Доверительным интервалом уровня доверия γ называется случайный интервал

$$[L(X), R(X)]$$

такой, что

$$\mathbb{P}_\theta(L(X) \leq \theta \leq R(X)) \geq \gamma.$$

Здесь:

$$\gamma = 1 - \alpha.$$

$$\gamma$$

называется уровнем доверия или надёжностью.

$$\alpha$$

в дальнейшем будет называться уровнем значимости.

32 Типичные уровни доверия

Обычно берут:

$$\gamma = 0.90, \quad \gamma = 0.95, \quad \gamma = 0.99.$$

Если:

$$\gamma = 0.95,$$

то говорят о доверительном интервале уровня 95%.

33 Как понимать доверительный интервал

Важно:

$$\theta \text{ не случайна, случайны границы интервала.}$$

Если много раз повторить эксперимент:

1. получить выборку;
2. построить интервал;
3. проверить, попал ли настоящий параметр внутрь;

то примерно в доле γ случаев интервал будет покрывать настоящий параметр. Например, при $\gamma = 0.95$ примерно 95 интервалов из 100 будут удачными.

34 Длина доверительного интервала

Длина интервала:

$$R(X) - L(X).$$

На лекции она также называлась точностью интервала.

Чем короче интервал при том же уровне доверия, тем точнее оценивание.

Но обычно:

$\gamma \uparrow \implies \text{интервал становится шире.}$

То есть высокий уровень доверия требует большей длины интервала.

35 Типовая схема построения доверительного интервала

Пусть

$$\hat{\theta}$$

— точечная оценка параметра θ .

Часто оказывается, что величина

$$\sqrt{n}(\hat{\theta} - \theta)$$

имеет или приближённо имеет распределение с функцией распределения F , не зависящее от θ .

Обозначим квантиль порядка α этого распределения через:

$$q_{\alpha}.$$

Тогда:

$$\mathbb{P}\left(q_{\frac{1-\gamma}{2}} \leq \sqrt{n}(\hat{\theta} - \theta) \leq q_{\frac{1+\gamma}{2}}\right) \approx \gamma.$$

36 Вывод формулы интервала

Из неравенства:

$$q_{\frac{1-\gamma}{2}} \leq \sqrt{n}(\hat{\theta} - \theta) \leq q_{\frac{1+\gamma}{2}}$$

делим на $\sqrt{n}$:

$$\frac{q_{\frac{1-\gamma}{2}}}{\sqrt{n}} \leq \hat{\theta} - \theta \leq \frac{q_{\frac{1+\gamma}{2}}}{\sqrt{n}}.$$

Выражаем θ .

Из левой части:

$$\hat{\theta} - \theta \geq \frac{q_{\frac{1-\gamma}{2}}}{\sqrt{n}}$$

получаем:

$$\theta \leq \hat{\theta} - \frac{q_{\frac{1-\gamma}{2}}}{\sqrt{n}}.$$

Из правой части:

$$\hat{\theta} - \theta \leq \frac{q_{\frac{1+\gamma}{2}}}{\sqrt{n}}$$

получаем:

$$\theta \geq \hat{\theta} - \frac{q_{\frac{1+\gamma}{2}}}{\sqrt{n}}.$$

Итак, доверительный интервал:

$$\left[\hat{\theta} - \frac{q_{\frac{1+\gamma}{2}}}{\sqrt{n}}, \quad \hat{\theta} - \frac{q_{\frac{1-\gamma}{2}}}{\sqrt{n}} \right].$$

Если записывать через $\alpha = 1 - \gamma$, то:

$$\left[\hat{\theta} - \frac{q_{1-\alpha/2}}{\sqrt{n}}, \quad \hat{\theta} - \frac{q_{\alpha/2}}{\sqrt{n}} \right].$$

37 Что такое квантиль

Определение 7. Квантиль порядка a — это число q_a , такое что распределение имеет слева от него вероятность примерно a .

В непрерывном случае:

$$F(q_a) = a.$$

В общем случае можно писать аккуратнее:

$$F(q_a) \geq a.$$

Например, медиана — это квантиль порядка

$$\frac{1}{2}.$$

38 Проблема неизвестного распределения

Формула доверительного интервала хороша, если известно распределение F . Но на текущем этапе часто неизвестно, как получить распределение величины

$$\sqrt{n}(\hat{\theta} - \theta).$$

Поэтому появляется проблема:

нужно приблизить неизвестное распределение F .

Для этого используется bootstrap.

39 Bootstrap: основная идея

Пусть есть наблюдаемая выборка:

$$x_1, \dots, x_n.$$

По ней строится эмпирическое распределение:

$$\mathbb{P}^*(X = x_i) = \frac{1}{n}, \quad i = 1, \dots, n.$$

Из этого эмпирического распределения многократно генерируются новые выборки объёма n :

$$X_1^{*(b)}, \dots, X_n^{*(b)}, \quad b = 1, \dots, B.$$

Для каждой bootstrap-выборки считается оценка:

$$\hat{\theta}^{*(b)}.$$

40 Bootstrap-выборки

Алгоритм:

1. Есть исходная выборка:

$$x_1, \dots, x_n.$$

2. Генерируем B bootstrap-выборок размера n с возвращением из исходных наблюдений.

3. Для каждой bootstrap-выборки считаем оценку:

$$\hat{\theta}^{*(b)}.$$

4. Получаем набор:

$$\hat{\theta}^{*(1)}, \dots, \hat{\theta}^{*(B)}.$$

Смысл:

bootstrap имитирует повторение эксперимента, используя только имеющиеся данные.

41 Bootstrap-аппроксимация распределения

Мы хотим приблизить распределение:

$$\sqrt{n}(\hat{\theta} - \theta).$$

Так как θ неизвестна, в bootstrap вместо неё используют исходную оценку

$$\hat{\theta}.$$

Для каждой bootstrap-выборки рассматривают:

$$Z_b^* = \sqrt{n}(\hat{\theta}^{*(b)} - \hat{\theta}).$$

Набор значений:

$$Z_1^*, \dots, Z_B^*$$

используется как выборка из приближённого распределения величины

$$\sqrt{n}(\hat{\theta} - \theta).$$

42 Bootstrap-доверительный интервал

Пусть

$$\hat{q}_{\alpha/2} \quad \text{и} \quad \hat{q}_{1-\alpha/2}$$

— выборочные квантили набора

$$Z_1^*, \dots, Z_B^*.$$

Тогда bootstrap-интервал можно записать как:

$$\left[\hat{\theta} - \frac{\hat{q}_{1-\alpha/2}}{\sqrt{n}}, \quad \hat{\theta} - \frac{\hat{q}_{\alpha/2}}{\sqrt{n}} \right].$$

Это соответствует общей схеме, только неизвестные теоретические квантили заменены bootstrap-квантилями.

43 Пример: Бернулли и bootstrap

Пусть:

$$X_i \sim \text{Bern}(p).$$

Точечная оценка:

$$\hat{p} = \overline{X}.$$

Для bootstrap:

1. строим эмпирическое распределение:

$$\mathbb{P}^*(1) = \hat{p}, \quad \mathbb{P}^*(0) = 1 - \hat{p};$$

2. генерируем много bootstrap-выборок;
3. для каждой считаем:

$$\hat{p}^{*(b)};$$

4. строим значения:

$$Z_b^* = \sqrt{n}(\hat{p}^{*(b)} - \hat{p});$$

5. берём квантили Z_b^* ;
6. получаем доверительный интервал для p .

44 Что происходит при увеличении объёма выборки

В лекции на экспериментах с boxplot было показано:

$n \uparrow \implies$ оценки концентрируются ближе к истинному значению параметра.

То есть при увеличении объёма выборки:

- разброс оценок уменьшается;
- MSE уменьшается;
- доверительные интервалы становятся уже;
- оценка становится стабильнее.

45 Что важно уметь объяснить на ответе

1. Что такое MLE

Метод максимального правдоподобия выбирает параметр, при котором наблюдаемая выборка имеет максимальную вероятность.

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} L(\theta).$$

2. Что такое функция правдоподобия

Это совместная вероятность или плотность выборки, рассматриваемая как функция параметра.

$$L(\theta) = \prod_{i=1}^n f_{\theta}(x_i).$$

3. Зачем брать логарифм

Логарифм превращает произведение в сумму и не меняет точку максимума, потому что он строго возрастает.

4. Какая MLE у Бернулли

$$\hat{p}_{\text{MLE}} = \overline{X}.$$

5. Какая MLE у геометрического распределения

Если X — число неудач до первого успеха:

$$\hat{p}_{\text{MLE}} = \frac{1}{1 + \overline{X}}.$$

Если X — номер первого успеха:

$$\hat{p}_{\text{MLE}} = \frac{1}{\overline{X}}.$$

6. Какая MLE у дискретного равномерного распределения

Если

$$X_i \sim \text{Unif}\{1, \dots, m\},$$

то:

$$\hat{m}_{\text{MLE}} = \max_i X_i.$$

7. Что такое доверительный интервал

Это случайный интервал, который с вероятностью примерно γ накрывает истинный параметр.

8. Как понимать уровень доверия

Если много раз повторить эксперимент, то примерно в доле γ случаев построенный интервал накроет настоящий параметр.

9. Зачем нужен bootstrap

Чтобы приблизить распределение оценки, когда теоретическое распределение неизвестно.

10. Как строится bootstrap-интервал

Генерируются bootstrap-выборки, по ним считаются bootstrap-оценки, затем берутся квантили приближённого распределения ошибки оценки.

46 Мини-шпаргалка

Функция правдоподобия

$$L(\theta) = \prod_{i=1}^n f_{\theta}(x_i).$$

Логарифм правдоподобия

$$\ell(\theta) = \ln L(\theta).$$

MLE

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} L(\theta) = \arg \max_{\theta} \ell(\theta).$$

Дискретное равномерное

$$X_i \sim \text{Unif}\{1, \dots, m\} \Rightarrow \hat{m}_{\text{MLE}} = \max_i X_i.$$

Бернулли

$$X_i \sim \text{Bern}(p) \Rightarrow \hat{p}_{\text{MLE}} = \overline{X}.$$

Геометрическое распределение

$$\mathbb{P}(X = x) = (1 - p)^x p, \quad x = 0, 1, 2, \dots \Rightarrow \hat{p}_{\text{MLE}} = \frac{1}{1 + \overline{X}}.$$

Категориальное распределение

$$\hat{p}_j = \frac{\nu_j}{n}.$$

Смещение

$$\text{Bias}(\hat{\theta}) = \mathbb{E}\hat{\theta} - \theta.$$

MSE

$$\text{MSE}(\hat{\theta}) = \mathbb{E}(\hat{\theta} - \theta)^2.$$

Доверительный интервал

$$\mathbb{P}_{\theta}(L(X) \leq \theta \leq R(X)) \geq \gamma.$$

Уровень доверия

$$\gamma = 1 - \alpha.$$

Типовая формула интервала

$$\left[\hat{\theta} - \frac{q_{1-\alpha/2}}{\sqrt{n}}, \quad \hat{\theta} - \frac{q_{\alpha/2}}{\sqrt{n}} \right].$$

Bootstrap-ошибка

$$Z_b^* = \sqrt{n}(\hat{\theta}^{*(b)} - \hat{\theta}).$$

47 Главное, что нужно запомнить

1. Метод максимального правдоподобия выбирает параметр, при котором наблюдаемая выборка наиболее вероятна.
2. Функция правдоподобия — это совместная вероятность выборки как функция параметра.
3. Логарифм правдоподобия удобнее функции правдоподобия, потому что произведение превращает в сумму.
4. Логарифм не меняет точку максимума.
5. Для дискретного равномерного распределения на $\{1, \dots, m\}$ MLE равна максимуму выборки.
6. Для распределения Бернулли MLE параметра p равна выборочному среднему.
7. Для геометрического распределения формула MLE зависит от выбранной договорённости о носителе.
8. Для категориального распределения MLE вероятностей равна относительным частотам.
9. Смещение показывает, насколько математическое ожидание оценки отличается от истинного параметра.
10. MSE показывает среднеквадратичное отклонение оценки от параметра.
11. Доверительный интервал оценивает параметр не одним числом, а интервалом.
12. Уровень доверия γ означает долгосрочную долю успешных интервалов при многократном повторении эксперимента.
13. Классическая формула доверительного интервала строится через квантили распределения ошибки оценки.
14. Если это распределение неизвестно, его можно приближать bootstrap-методом.
15. Bootstrap генерирует много выборок из эмпирического распределения и по ним оценивает распределение оценки.