

Конспект по статистике

Введение в статистику. Модель простейшей выборки

Лекция от 27.03.2026

Основные темы лекции

1. Чем статистика отличается от теории вероятностей.
2. Генеральная совокупность и выборка.
3. Репрезентативность выборки.
4. Примеры статистических задач.
5. Модель простейшей выборки.
6. Независимые одинаково распределённые случайные величины.
7. Теоретическая функция распределения.
8. Реализация выборки.
9. Эмпирическая функция распределения.
10. Эмпирическое распределение.
11. Несмещённость и состоятельность эмпирической функции распределения.
12. Визуализация выборки: гистограмма, boxplot, violin plot.
13. Вариационный ряд.
14. Медиана, квантили, квартили, перцентили, децили.
15. Порядковые статистики.

Содержание

1	Общий переход от теории вероятностей к статистике	4
2	Генеральная совокупность	4
3	Выборка	5
4	Репрезентативность	5
4.1	Почему большой объём выборки не гарантирует репрезентативность	5
4.2	Объём выборки	5
5	Как можно собирать выборку	6

6	Стратифицированная выборка	6
7	Примеры статистических задач	6
7.1	Пример 1: робот бросает монету	6
7.2	Пример 2: влияние вещества на здоровье	7
7.3	Пример 3: цена квартиры	7
7.4	Пример 4: сравнение двух групп	8
8	Модель простейшей выборки	8
9	Почему выборку считают случайной	8
10	Реализация выборки	9
11	Теоретическая функция распределения	9
12	Эмпирическая функция распределения	9
13	График эмпирической функции распределения	10
14	Эмпирическое распределение	10
15	Статистика	11
16	Распределение величины $\mu_n(t)$	11
17	Математическое ожидание эмпирической функции распределения	12
18	Несмещённость	12
19	Дисперсия эмпирической функции распределения	13
20	Состоятельность эмпирической функции распределения	13
21	Связь с законом больших чисел	14
22	Визуализация выборки	15
23	Гистограмма	15
24	Boxplot	15
25	Межквартильный размах	16
26	Violin plot	16
27	Вариационный ряд	16
28	Интервальный вариационный ряд	17
29	Выборочная медиана	17
30	Выборочные квантили	18
30.1	Частные случаи	18

31 Квартили	19
32 Перцентили	19
33 Децили	20
34 Порядковые статистики	20
35 Мини-шпаргалка	20
36 Главное, что нужно запомнить	22

1 Общий переход от теории вероятностей к статистике

В начале лекции был сделан переход от теории вероятностей к математической статистике.

Если говорить неформально, то в теории вероятностей обычно задана вероятностная модель.

Например, известно распределение случайной величины. Тогда по нему можно найти:

- вероятности событий;
- математическое ожидание;
- дисперсию;
- распределения новых случайных величин;
- другие числовые характеристики.

В статистике задача во многом обратная.

В статистике у нас есть данные, и по ним нужно сделать выводы о неизвестной модели.

То есть:

данные $\implies$ выводы о распределении, параметрах или зависимости.

2 Генеральная совокупность

Определение 1. Генеральная совокупность — это совокупность всех объектов, которые нас интересуют в задаче.

Например:

- множество всех студентов университета;
- множество всех жителей города;
- множество всех квартир на рынке;
- множество всех бросков некоторой монеты;
- множество всех пациентов, для которых потенциально применимо лекарство.

Обычно исследовать каждый объект из генеральной совокупности невозможно:

- объектов слишком много;
- это дорого;
- это долго;
- часть объектов недоступна;
- измерения могут разрушать объект.

Поэтому вместо всей генеральной совокупности рассматривают выборку.

3 Выборка

Определение 2. Выборка — это конечный набор объектов, взятых из генеральной совокупности.

Если генеральная совокупность огромная, то выборка является лишь её небольшой частью.

Главная идея статистики:

по выборке сделать выводы о всей генеральной совокупности.

Но для этого выборка должна быть хорошей.

4 Репрезентативность

Определение 3. Выборка называется репрезентативной, если по ней можно делать содержательные выводы о всей генеральной совокупности.

Иначе говоря, выборка должна достаточно хорошо отражать структуру генеральной совокупности.

4.1 Почему большой объём выборки не гарантирует репрезентативность

В лекции обсуждался пример с онлайн-анкетой.

Пусть анкету в интернете прошли сотни тысяч людей. На первый взгляд выборка большая.

Но она может быть нерепрезентативной, потому что:

- в неё попадут в основном люди, активно пользующиеся интернетом;
- люди без доступа к интернету не попадут почти никогда;
- участие добровольное, значит, отвечают неслучайные люди;
- некоторые группы населения будут пере- или недопредставлены.

Поэтому:

большой объём выборки не равен репрезентативности.

4.2 Объём выборки

Определение 4. Объём выборки — это количество наблюдений в выборке.

Обычно он обозначается буквой n .

Если выборка имеет вид

$$x_1, x_2, \dots, x_n,$$

то её объём равен n .

5 Как можно собирать выборку

Один простой способ — случайный отбор.

Но в реальных задачах этого может быть недостаточно.

Например, если проводится социологический опрос, то важно, чтобы в выборке были представлены разные группы людей.

6 Стратифицированная выборка

Определение 5. Стратификация — это разбиение генеральной совокупности на группы, или страты, перед отбором элементов.

Например, людей можно разбить по:

- возрасту;
- полу;
- региону;
- образованию;
- доходу;
- профессии.

После этого из каждой страты выбирают некоторое количество объектов.

Стратификация помогает не потерять важные группы генеральной совокупности.

Важно: способ сбора данных зависит от предметной области.

В социологии, медицине, экономике, промышленности и биологии протоколы сбора данных могут быть разными.

7 Примеры статистических задач

7.1 Пример 1: робот бросает монету

Пусть робот много раз бросает монету, и мы записываем результаты.

Например:

$$1, 0, 1, 1, 0, 0, 1, \dots$$

где

1 — орёл,

0 — решка.

Какие задачи можно поставить?

1. Оценить вероятность выпадения орла.

2. Оценить вероятность выпадения решки.
3. Построить интервал, в котором с высокой уверенностью лежит вероятность орла.
4. Проверить гипотезу: честная ли монета.
5. Понять, сколько бросков нужно, чтобы оценка была достаточно точной.

Простейшая оценка вероятности орла:

$$\hat{p} = \frac{\text{число орлов}}{\text{общее число бросков}}.$$

Позже в курсе обсуждается, почему такая оценка естественна и какими свойствами она обладает.

7.2 Пример 2: влияние вещества на здоровье

Пусть есть некоторое вещество и нужно понять, влияет ли оно на здоровье человека. Возможны разные постановки:

- влияет ли вещество вообще;
- влияет ли оно положительно;
- влияет ли оно отрицательно.

Эти вопросы похожи, но статистически они могут формулироваться по-разному. Например:

- для лекарства важно доказать положительный эффект;
- для токсичного вещества важно обнаружить отрицательный эффект;
- для нейтрального вещества важно проверить отсутствие заметного эффекта.

7.3 Пример 3: цена квартиры

Пусть есть показатель — цена квартиры. Она может зависеть от разных факторов:

- количество комнат;
- площадь;
- качество ремонта;
- расстояние до метро;
- район;
- этаж;
- тип дома.

Статистическая задача:

понять, какие факторы действительно статистически значимо влияют на цену.

То есть отличить реальное влияние от случайного шума.

7.4 Пример 4: сравнение двух групп

Можно сравнивать две группы людей по некоторому показателю. Например, отличаются ли учебные результаты у двух групп. Здесь могут использоваться методы:

- сравнения средних;
- сравнения дисперсий;
- анализа корреляций;
- проверки статистических гипотез.

При этом размеры групп могут быть разными. Хорошие статистические методы должны это учитывать.

8 Модель простейшей выборки

Теперь переходим к математической модели. Пусть есть случайные величины

$$X_1, X_2, \dots, X_n.$$

Определение 6. Модель простейшей выборки предполагает, что $X_1, \dots, X_n$ — независимые одинаково распределённые случайные величины.

То есть:

$X_1, \dots, X_n$ независимы и имеют одно и то же распределение.

Часто используют сокращение:

$X_1, \dots, X_n$ i.i.d.

Это сокращение от английского:

independent identically distributed.

На русском:

независимые одинаково распределённые.

9 Почему выборку считают случайной

Выборку воспринимают как набор случайных величин, потому что результат эксперимента заранее неизвестен.

Если провести эксперимент один раз, получим одни числа.

Если повторить эксперимент, получим другие числа.

Например:

$$X_1, \dots, X_n$$

— случайные величины до наблюдения.

А после проведения эксперимента мы получаем конкретные числа

$$x_1, \dots, x_n.$$

10 Реализация выборки

Определение 7. Реализация выборки — это конкретный набор чисел, полученный после проведения эксперимента.

Обозначение:

$$X_1, \dots, X_n$$

— случайные величины.

$$x_1, \dots, x_n$$

— конкретная реализация.

То есть:

большие буквы — случайные величины, маленькие — наблюдаемые числа.

11 Теоретическая функция распределения

Так как $X_1, \dots, X_n$ одинаково распределены, у них есть общая функция распределения. Обозначим её:

$$F(t) = \mathbb{P}(X_1 \leq t).$$

Определение 8. Функция $F(t)$ называется теоретической функцией распределения.

В статистике она обычно неизвестна.

Цель:

по выборке $X_1, \dots, X_n$ оценить неизвестную функцию F .

12 Эмпирическая функция распределения

Чтобы оценить $F(t)$, вводят эмпирическую функцию распределения. Сначала определим число наблюдений, не превосходящих t :

$$\mu_n(t) = \sum_{k=1}^n \mathbf{1}_{\{X_k \leq t\}}.$$

Здесь

$$\mathbf{1}_{\{X_k \leq t\}}$$

— индикатор события $X_k \leq t$.

Он равен:

$$\mathbf{1}_{\{X_k \leq t\}} = \begin{cases} 1, & X_k \leq t, \\ 0, & X_k > t. \end{cases}$$

То есть $\mu_n(t)$ считает, сколько элементов выборки не превосходит t .

Определение 9. Эмпирической функцией распределения называется функция

$$F_n(t) = \frac{\mu_n(t)}{n} = \frac{1}{n} \sum_{k=1}^n \mathbf{1}_{\{X_k \leq t\}}.$$

Иначе говоря,

$$F_n(t) = \frac{\text{число элементов выборки, не превосходящих } t}{n}.$$

13 График эмпирической функции распределения

Пусть дана конкретная реализация выборки.

Например, есть значения

$$x_1 < x_2 < x_3 < x_4,$$

причём x_2 встречается два раза.

Тогда объём выборки равен

$$n = 5.$$

Эмпирическая функция распределения имеет вид ступенчатой функции.

- До первого наблюдения она равна 0.
- В точке x_1 происходит скачок на $\frac{1}{5}$.
- В точке x_2 происходит скачок на $\frac{2}{5}$, потому что это значение встретилось два раза.
- В точках x_3 и x_4 происходят скачки на $\frac{1}{5}$.
- После максимального наблюдения функция равна 1.

Эмпирическая функция распределения всегда ступенчатая.

14 Эмпирическое распределение

Эмпирическая функция распределения задаёт эмпирическое распределение.

Если в реализации выборки значение x встретилось m_x раз, то эмпирическая вероятность этого значения равна

$$\mathbb{P}_{\text{emp}}(X = x) = \frac{m_x}{n}.$$

То есть:

эмпирическое распределение кладёт массу $\frac{1}{n}$ в каждое наблюдение.

Если некоторые значения повторяются, их массы складываются.

15 Статистика

Определение 10. Статистика — это функция от выборки.

То есть если

$$T = T(X_1, \dots, X_n),$$

то T называется статистикой.

Примеры статистик:

- выборочное среднее;
- выборочная дисперсия;
- выборочная медиана;
- максимум выборки;
- минимум выборки;
- эмпирическая функция распределения $F_n(t)$ при фиксированном t .

Важно:

статистика является случайной величиной, потому что зависит от случайной выборки.

16 Распределение величины $\mu_n(t)$

Рассмотрим фиксированное t .

Индикатор

$$\mathbf{1}_{\{X_k \leq t\}}$$

принимает значения 0 и 1.

Вероятность того, что он равен 1:

$$\mathbb{P}(X_k \leq t) = F(t).$$

Значит,

$$\mathbf{1}_{\{X_k \leq t\}}$$

имеет распределение Бернулли с параметром $F(t)$:

$$\mathbf{1}_{\{X_k \leq t\}} \sim \text{Bernoulli}(F(t)).$$

Так как $X_1, \dots, X_n$ независимы, то индикаторы тоже независимы.

Поэтому сумма

$$\mu_n(t) = \sum_{k=1}^n \mathbf{1}_{\{X_k \leq t\}}$$

имеет биномиальное распределение:

$$\mu_n(t) \sim \text{Bin}(n, F(t)).$$

17 Математическое ожидание эмпирической функции распределения

Так как

$$F_n(t) = \frac{\mu_n(t)}{n},$$

то

$$\mathbb{E}F_n(t) = \mathbb{E}\left(\frac{\mu_n(t)}{n}\right).$$

По линейности математического ожидания:

$$\mathbb{E}F_n(t) = \frac{1}{n}\mathbb{E}\mu_n(t).$$

Если

$$\mu_n(t) \sim \text{Bin}(n, F(t)),$$

то

$$\mathbb{E}\mu_n(t) = nF(t).$$

Значит,

$$\mathbb{E}F_n(t) = \frac{1}{n}nF(t) = F(t).$$

Получаем:

$$\boxed{\mathbb{E}F_n(t) = F(t).}$$

18 Несмещённость

Определение 11. Оценка называется несмещённой, если её математическое ожидание равно оцениваемой величине.

Для эмпирической функции распределения:

$$\boxed{\mathbb{E}F_n(t) = F(t).}$$

Значит, $F_n(t)$ является несмещённой оценкой $F(t)$.

Интуитивно:

$\boxed{\text{в среднем эмпирическая функция распределения попадает в теоретическую.}}$

Она может ошибаться в конкретном эксперименте, но систематической ошибки нет.

19 Дисперсия эмпирической функции распределения

Найдём дисперсию:

$$\mathrm{Var}(F_n(t)) = \mathrm{Var}\left(\frac{\mu_n(t)}{n}\right).$$

Константа из дисперсии выносится в квадрат:

$$\mathrm{Var}(F_n(t)) = \frac{1}{n^2} \mathrm{Var}(\mu_n(t)).$$

Для биномиального распределения

$$\mu_n(t) \sim \mathrm{Bin}(n, F(t))$$

дисперсия равна

$$\mathrm{Var}(\mu_n(t)) = nF(t)(1 - F(t)).$$

Следовательно,

$$\mathrm{Var}(F_n(t)) = \frac{1}{n^2} nF(t)(1 - F(t)).$$

Итак,

$$\mathrm{Var}(F_n(t)) = \frac{F(t)(1 - F(t))}{n}.$$

20 Состоятельность эмпирической функции распределения

Для доказательства сходимости используется неравенство Чебышёва.

Теорема 1 (Неравенство Чебышёва). *Для случайной величины Y с конечной дисперсией:*

$$\mathbb{P}(|Y - \mathbb{E}Y| \geq \varepsilon) \leq \frac{\mathrm{Var}(Y)}{\varepsilon^2}.$$

Применим его к

$$Y = F_n(t).$$

Так как

$$\mathbb{E}F_n(t) = F(t),$$

получаем:

$$\mathbb{P}(|F_n(t) - F(t)| \geq \varepsilon) \leq \frac{\mathrm{Var}(F_n(t))}{\varepsilon^2}.$$

Подставляем дисперсию:

$$\mathbb{P}(|F_n(t) - F(t)| \geq \varepsilon) \leq \frac{F(t)(1 - F(t))}{n\varepsilon^2}.$$

Правая часть стремится к нулю при $n \rightarrow \infty$:

$$\frac{F(t)(1 - F(t))}{n\varepsilon^2} \rightarrow 0.$$

Значит,

$$\mathbb{P}(|F_n(t) - F(t)| \geq \varepsilon) \rightarrow 0.$$

Это означает, что

$$F_n(t)$$

сходится к

$$F(t)$$

по вероятности.

Определение 12. Оценка называется состоятельной, если при увеличении объёма выборки она стремится к оцениваемой величине.

Получаем:

$$F_n(t) \text{ — состоятельная оценка } F(t).$$

Интуитивно:

чем больше выборка, тем ближе эмпирическая функция распределения к теоретической.

21 Связь с законом больших чисел

Формула

$$F_n(t) = \frac{1}{n} \sum_{k=1}^n \mathbf{1}_{\{X_k \leq t\}}$$

является средним арифметическим независимых одинаково распределённых индикаторов.

Поэтому сходимость

$$F_n(t) \rightarrow F(t)$$

является проявлением закона больших чисел.

эмпирическая доля успехов стремится к истинной вероятности успеха.

22 Визуализация выборки

После эмпирической функции распределения обсуждались способы визуализации данных.

Основные инструменты:

- гистограмма;
- boxplot;
- violin plot.

23 Гистограмма

Определение 13. Гистограмма — это график, который показывает, сколько элементов выборки попало в каждый интервал.

Идея:

1. разбить ось значений на интервалы;
2. посчитать количество наблюдений в каждом интервале;
3. нарисовать столбцы соответствующей высоты.

Если на оси Y откладывать количество элементов, получаем обычную гистограмму частот.

Если откладывать долю элементов, получаем нормированную гистограмму.

нормированная гистограмма удобна для сравнения выборок разного размера.

В дискретном случае гистограмма приближает функцию вероятностей.

В непрерывном случае она приближает плотность распределения.

24 Boxplot

Boxplot, или ящик с усами, показывает основные порядковые характеристики выборки. На нём обычно отображаются:

- медиана;
- нижний квартиль;
- верхний квартиль;
- межквартильный размах;
- возможные выбросы.

Центральная линия внутри прямоугольника — медиана.

Границы прямоугольника:

- нижний квартиль Q_1 ;

- верхний квартиль Q_3 .

Разность

$$Q_3 - Q_1$$

называется межквартильным размахом.

25 Межквартильный размах

Определение 14. Межквартильный размах — это разность между верхним и нижним квартилями.

Обозначение:

$$IQR = Q_3 - Q_1.$$

В boxplot обычно “усы” откладываются на расстояние примерно

$$1.5 \cdot IQR$$

от границ ящика.

Точки, которые выходят за этот диапазон, часто отображаются отдельно и интерпретируются как потенциальные выбросы.

26 Violin plot

Violin plot можно неформально понимать как комбинацию:

$$\text{violin plot} \approx \text{boxplot} + \text{сглаженная гистограмма}.$$

Он показывает:

- форму распределения;
- концентрацию наблюдений;
- медиану и квартильную структуру;
- возможную асимметрию.

27 Вариационный ряд

Пусть дана реализация выборки:

$$x_1, x_2, \dots, x_n.$$

Если отсортировать её по возрастанию, получим:

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}.$$

Определение 15. Отсортированная выборка

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$$

называется вариационным рядом.

Скобки в индексе показывают, что это не исходный номер наблюдения, а номер после сортировки.

28 Интервальный вариационный ряд

Иногда значения группируют по интервалам.

Пусть заданы интервалы:

$$[a_1, b_1), [a_2, b_2), \dots, [a_m, b_m),$$

где

$$b_k = a_{k+1}.$$

Для каждого интервала считают количество элементов выборки, попавших в него:

$$\nu_k = \#\{i : x_i \in [a_k, b_k)\}.$$

Таблица вида

интервал	число наблюдений
$[a_1, b_1)$	ν_1
$[a_2, b_2)$	ν_2
$\vdots$	$\vdots$
$[a_m, b_m)$	ν_m

называется интервальным вариационным рядом.

Именно по такой таблице удобно строить гистограмму.

29 Выборочная медиана

Медиана — это значение, которое делит выборку примерно пополам.

Определение 16. Выборочная медиана — это центральный элемент вариационного ряда, если n нечётно, и среднее двух центральных элементов, если n чётно.

Если

$$n = 2k + 1,$$

то

$\text{Med} = x_{(k+1)}.$

Если

$$n = 2k,$$

то

$$\text{Med} = \frac{x_{(k)} + x_{(k+1)}}{2}.$$

Иногда используют и другие соглашения, например брать элемент вариационного ряда с номером $\lfloor n/2 \rfloor$. Главное понимать смысл:

примерно половина наблюдений не больше медианы, и примерно половина не меньше.

30 Выборочные квантили

Определение 17. Выборочный квантиль порядка α , где $0 \leq \alpha \leq 1$, — это значение, левее которого находится примерно доля α выборки.

Грубо:

$$q_\alpha \approx x_{(\lfloor n\alpha \rfloor)}.$$

Точные определения квантилей могут немного отличаться в разных программах и учебниках.

Смысл:

доля α наблюдений находится ниже квантиля,

доля $1 - \alpha$ наблюдений находится выше.

30.1 Частные случаи

При

$$\alpha = 0$$

квантиль — минимум:

$$q_0 = x_{(1)}.$$

При

$$\alpha = 1$$

квантиль — максимум:

$$q_1 = x_{(n)}.$$

При

$$\alpha = \frac{1}{2}$$

квантиль — медиана.

31 Квартили

Квартили делят выборку на четыре части.

Основные квартили:

$$Q_0 = q_0,$$

$$Q_1 = q_{1/4},$$

$$Q_2 = q_{1/2},$$

$$Q_3 = q_{3/4},$$

$$Q_4 = q_1.$$

Здесь:

- Q_0 — минимум;
- Q_1 — нижний квартиль;
- Q_2 — медиана;
- Q_3 — верхний квартиль;
- Q_4 — максимум.

$$Q_k = q_{k/4}.$$

32 Перцентили

Определение 18. Перцентиль порядка x — это квантиль порядка $\frac{x}{100}$.

То есть:

$$x\text{-й перцентиль} = q_{x/100}.$$

Например:

$$25\text{-й перцентиль} = q_{0.25} = Q_1,$$

$$50\text{-й перцентиль} = q_{0.5} = Q_2 = \text{Med},$$

$$75\text{-й перцентиль} = q_{0.75} = Q_3.$$

33 Децили

Децили делят выборку на десять частей.

$$k\text{-й дециль} = q_{k/10}.$$

Например:

$$1\text{-й дециль} = q_{0.1},$$

$$5\text{-й дециль} = q_{0.5} = \text{Med},$$

$$9\text{-й дециль} = q_{0.9}.$$

34 Порядковые статистики

Определение 19. k -я порядковая статистика — это k -й элемент вариационного ряда.

То есть

$$X_{(k)}$$

— это k -я порядковая статистика.

Например:

$$X_{(1)}$$

— минимум выборки,

$$X_{(n)}$$

— максимум выборки,

$$X_{(\lfloor n/2 \rfloor)}$$

— связан с медианой.

Квантили, квартили, перцентили и децили выражаются через порядковые статистики.

35 Мини-шпаргалка

Генеральная совокупность

все объекты, которые нас интересуют.

Выборка

конечный набор объектов из генеральной совокупности.

Репрезентативность

по выборке можно делать выводы о генеральной совокупности.

Модель простейшей выборки

$X_1, \dots, X_n$ независимы и одинаково распределены.

$X_1, \dots, X_n$ i.i.d.

Теоретическая функция распределения

$$F(t) = \mathbb{P}(X_1 \leq t).$$

Эмпирическая функция распределения

$$F_n(t) = \frac{1}{n} \sum_{k=1}^n \mathbf{1}_{\{X_k \leq t\}}.$$

Число наблюдений не больше t

$$\mu_n(t) = \sum_{k=1}^n \mathbf{1}_{\{X_k \leq t\}}.$$

$$\mu_n(t) \sim \text{Bin}(n, F(t)).$$

Несмещённость

$$\mathbb{E}F_n(t) = F(t).$$

Дисперсия

$$\text{Var}(F_n(t)) = \frac{F(t)(1 - F(t))}{n}.$$

Состоятельность

$$\mathbb{P}(|F_n(t) - F(t)| \geq \varepsilon) \rightarrow 0.$$

Вариационный ряд

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}.$$

Медиана

$$\text{Med} = x_{(k+1)}, \quad n = 2k + 1.$$

$$\text{Med} = \frac{x_{(k)} + x_{(k+1)}}{2}, \quad n = 2k.$$

Межквартильный размах

$$IQR = Q_3 - Q_1.$$

Перцентиль

$$x\text{-й перцентиль} = q_{x/100}.$$

Порядковая статистика

$$X_{(k)} \text{ — } k\text{-й элемент отсортированной выборки.}$$

36 Главное, что нужно запомнить

1. Теория вероятностей обычно идёт от модели к выводам, а статистика — от данных к модели.
2. Генеральная совокупность — это все объекты, которые интересуют в задаче.
3. Выборка — конечная часть генеральной совокупности.
4. Большой объём выборки сам по себе не гарантирует репрезентативность.
5. Модель простейшей выборки предполагает, что наблюдения независимы и одинаково распределены.
6. Теоретическая функция распределения $F(t)$ неизвестна, и её нужно оценить по данным.
7. Эмпирическая функция распределения:

$$F_n(t) = \frac{1}{n} \sum_{k=1}^n \mathbf{1}_{\{X_k \leq t\}}.$$

8. Для фиксированного t :

$$\mu_n(t) \sim \text{Bin}(n, F(t)).$$

9. Эмпирическая функция распределения несмещённа:

$$\mathbb{E}F_n(t) = F(t).$$

10. Её дисперсия убывает как $\frac{1}{n}$:

$$\text{Var}(F_n(t)) = \frac{F(t)(1 - F(t))}{n}.$$

11. Поэтому $F_n(t)$ является состоятельной оценкой $F(t)$.

12. Гистограмма показывает распределение наблюдений по интервалам.

13. Boxplot показывает медиану, квартили, межквартильный размах и выбросы.

14. Вариационный ряд — это отсортированная выборка.

15. Медиана, квантили, квартили, перцентили и децили связаны с порядковыми статистиками.