

Конспект по ЧМА

Небольшое дополнение по сплайнам. Метод наименьших квадратов

Лекция от 19.03.2026

Основные темы лекции

1. Уточнение по кубическим сплайнам и граничным условиям.
2. Почему интерполяция не всегда подходит для табличных данных.
3. Идея метода наименьших квадратов.
4. Непрерывный и дискретный варианты задачи.
5. Аппроксимация в системе линейно независимых функций.
6. Нормальные уравнения метода наименьших квадратов.
7. Частный случай: аппроксимация многочленом.
8. Весовой метод наименьших квадратов.

Содержание

1	Дополнение по кубическим сплайнам	3
1.1	Уточнение про граничное условие	3
2	Почему одной интерполяции недостаточно	4
2.1	Проблема зашумлённых данных	4
3	Идея метода наименьших квадратов	4
4	Расстояние между функциями	5
4.1	Максимальное отклонение	5
4.2	Расстояние через скалярное произведение	5
5	Непрерывный случай	5
6	Дискретный случай	6
7	Аппроксимирующая функция	6
8	Линейная независимость функций	7

9	Три возможные ситуации	7
9.1	Случай 1: число точек равно числу коэффициентов	8
9.2	Случай 2: точек меньше, чем коэффициентов	8
9.3	Случай 3: точек больше, чем коэффициентов	8
10	Вывод нормальных уравнений	9
11	Матричная форма нормальных уравнений	10
12	Частный случай: многочлен степени m	10
13	Аппроксимация прямой	11
14	Влияние степени многочлена	12
15	Интерполяция или метод наименьших квадратов	12
16	Весовой метод наименьших квадратов	12
16.1	Функционал с весами	13
16.2	Взвешенное скалярное произведение	13
17	Геометрический смысл метода	13
18	Мини-шпаргалка	14
19	Главное, что нужно запомнить	15

1 Дополнение по кубическим сплайнам

В начале лекции обсуждалось небольшое уточнение к условиям для кубических сплайнов.

Кубический сплайн на каждом промежутке имеет вид многочлена третьей степени:

$$S_i(x) = a_i + b_i(x - x_i) + c_i(x - x_i)^2 + d_i(x - x_i)^3.$$

Здесь верхний индекс или нижний индекс обычно указывает номер промежутка.

Для кубического сплайна важно, чтобы на внутренних узлах выполнялись условия склейки:

$$S_i(x_i) = f_i,$$

$$S_i(x_{i+1}) = f_{i+1},$$

$$S'_i(x_{i+1}) = S'_{i+1}(x_{i+1}),$$

$$S''_i(x_{i+1}) = S''_{i+1}(x_{i+1}).$$

То есть сам сплайн, его первая производная и его вторая производная должны совпадать в узлах.

1.1 Уточнение про граничное условие

Для естественного кубического сплайна на концах отрезка обычно задают условия

$$S''(x_0) = 0, \quad S''(x_n) = 0.$$

То есть на концах отрезка обращается в ноль **вторая производная**, а не третья. Это важно.

Если бы требовать равенство нулю третьей производной, то для кубического многочлена

$$S_i(x) = a_i + b_i(x - x_i) + c_i(x - x_i)^2 + d_i(x - x_i)^3$$

третья производная была бы связана с коэффициентом d_i . Условие

$$S'''_i(x) = 0$$

заставило бы исчезнуть кубический член, то есть сплайн фактически перестал бы быть кубическим на соответствующем промежутке.

Поэтому корректное граничное условие для естественного кубического сплайна:

$$\text{на концах равна нулю вторая производная.}$$

2 Почему одной интерполяции недостаточно

Ранее рассматривалась интерполяция.

При интерполяции строится функция или многочлен, который проходит через все заданные точки:

$$Q(x_i) = f(x_i).$$

Если данные точные, это естественный подход.

Но на практике данные часто бывают неточными:

- есть погрешности измерений;
- значения округлены;
- прибор может давать шум;
- некоторые точки могут быть выбросами.

В такой ситуации интерполяционный многочлен может оказаться плохим приближением реальной зависимости.

2.1 Проблема зашумлённых данных

Пусть есть таблица значений

$$(x_0, f_0), \quad (x_1, f_1), \quad \dots, \quad (x_n, f_n).$$

Если точки лежат примерно вдоль некоторой гладкой кривой, но имеют небольшие отклонения, то интерполяционный многочлен будет вынужден пройти через каждую точку.

Из-за этого он может сильно колебаться.

Смысл метода наименьших квадратов другой:

нужно построить функцию, которая хорошо описывает общую тенденцию, но не обязана проходить

То есть мы хотим не интерполировать данные, а аппроксимировать их.

3 Идея метода наименьших квадратов

Пусть дана функция $f(x)$, которую нужно приблизить некоторой функцией $Q_m(x)$.

Функция $Q_m(x)$ зависит от параметров, которые нужно подобрать.

Например, это может быть многочлен степени m :

$$Q_m(x) = a_0 + a_1x + a_2x^2 + \dots + a_mx^m.$$

Метод наименьших квадратов выбирает коэффициенты

$$a_0, a_1, \dots, a_m$$

так, чтобы сумма квадратов отклонений была минимальной.

Метод наименьших квадратов минимизирует сумму квадратов ошибок.

4 Расстояние между функциями

Чтобы говорить о приближении одной функции другой, нужно ввести меру отклонения.

4.1 Максимальное отклонение

Можно измерять отклонение так:

$$\Delta = \max_{x \in [a, b]} |f(x) - Q_m(x)|.$$

Это равномерная ошибка.

Она показывает максимальное отклонение приближающей функции от исходной на всём отрезке.

Но метод наименьших квадратов использует другую идею: он минимизирует не максимум, а суммарный квадрат отклонений.

4.2 Расстояние через скалярное произведение

Если в пространстве функций задано скалярное произведение

$$\langle u, v \rangle,$$

то можно определить расстояние между функциями f и Q_m :

$$\rho(f, Q_m) = \|f - Q_m\| = \sqrt{\langle f - Q_m, f - Q_m \rangle}.$$

Тогда квадрат расстояния:

$$\boxed{\rho^2(f, Q_m) = \langle f - Q_m, f - Q_m \rangle.}$$

Именно квадрат этого расстояния минимизируется в методе наименьших квадратов.

5 Непрерывный случай

Если функция задана на отрезке $[a, b]$, то скалярное произведение функций часто задают интегралом:

$$\langle u, v \rangle = \int_a^b u(x)v(x) dx.$$

Тогда расстояние между f и Q_m равно

$$\rho(f, Q_m) = \sqrt{\int_a^b (f(x) - Q_m(x))^2 dx}.$$

Соответственно,

$$\boxed{\rho^2(f, Q_m) = \int_a^b (f(x) - Q_m(x))^2 dx.}$$

В непрерывном варианте метод наименьших квадратов требует найти такую функцию Q_m , чтобы величина

$$\int_a^b (f(x) - Q_m(x))^2 dx$$

была минимальной.

6 Дискретный случай

В лекции основное внимание уделяется дискретному случаю, когда функция задана таблицей:

$$\begin{array}{c|cccc} x & x_0 & x_1 & \dots & x_n \\ \hline f & f_0 & f_1 & \dots & f_n \end{array}$$

Здесь

$$f_i = f(x_i).$$

В дискретном случае скалярное произведение можно задать как сумму:

$$\langle u, v \rangle = \sum_{i=0}^n u(x_i)v(x_i).$$

Тогда расстояние между f и Q_m :

$$\rho(f, Q_m) = \sqrt{\sum_{i=0}^n (f_i - Q_m(x_i))^2}.$$

А квадрат расстояния:

$$\rho^2(f, Q_m) = \sum_{i=0}^n (f_i - Q_m(x_i))^2.$$

Метод наименьших квадратов в дискретном случае состоит в минимизации функции

$$S(a_0, \dots, a_m) = \sum_{i=0}^n (f_i - Q_m(x_i))^2.$$

7 Аппроксимирующая функция

В общем виде аппроксимирующую функцию можно искать не только среди обычных многочленов.

Пусть выбраны линейно независимые функции

$$\varphi_0(x), \varphi_1(x), \dots, \varphi_m(x).$$

Тогда приближающую функцию ищут в виде

$$Q_m(x) = a_0\varphi_0(x) + a_1\varphi_1(x) + \dots + a_m\varphi_m(x).$$

Коэффициенты

$$a_0, a_1, \dots, a_m$$

нужно подобрать.

Чаще всего выбирают

$$\varphi_0(x) = 1, \quad \varphi_1(x) = x, \quad \varphi_2(x) = x^2, \quad \dots, \quad \varphi_m(x) = x^m.$$

Тогда

$$Q_m(x) = a_0 + a_1x + \dots + a_mx^m.$$

Но можно выбирать и другие системы функций, например:

$$1, \quad \sin x, \quad \sin 2x, \quad \dots$$

или другие функции, если они лучше соответствуют природе задачи.

8 Линейная независимость функций

Определение 1. Функции

$$\varphi_0, \varphi_1, \dots, \varphi_m$$

называются линейно независимыми, если из равенства

$$c_0\varphi_0(x) + c_1\varphi_1(x) + \dots + c_m\varphi_m(x) \equiv 0$$

следует

$$c_0 = c_1 = \dots = c_m = 0.$$

Если существует хотя бы один ненулевой коэффициент c_k , при котором линейная комбинация равна нулю, то функции линейно зависимы.

Линейная независимость нужна для того, чтобы коэффициенты аппроксимации определялись однозначно.

9 Три возможные ситуации

Пусть есть $n + 1$ табличная точка:

$$(x_0, f_0), \dots, (x_n, f_n).$$

А аппроксимирующая функция ищется в виде

$$Q_m(x) = a_0\varphi_0(x) + \dots + a_m\varphi_m(x).$$

Здесь неизвестных коэффициентов $m + 1$.

9.1 Случай 1: число точек равно числу коэффициентов

Если

$$n + 1 = m + 1,$$

то есть

$$n = m,$$

то обычно можно построить интерполяционный многочлен, который проходит через все точки.

Тогда

$$Q_m(x_i) = f_i$$

для всех i , и

$$\rho^2 = \sum_{i=0}^n (f_i - Q_m(x_i))^2 = 0.$$

Это минимально возможное значение, потому что сумма квадратов не может быть отрицательной.

Значит, в этом случае метод наименьших квадратов совпадает с интерполяцией.

9.2 Случай 2: точек меньше, чем коэффициентов

Если

$$n + 1 < m + 1,$$

то данных меньше, чем неизвестных коэффициентов.

Например, мы хотим построить многочлен пятой степени, а точек наблюдения всего три.

В таком случае задача недоопределена: можно построить бесконечно много функций, которые проходят через заданные точки.

То есть единственного решения обычно нет.

9.3 Случай 3: точек больше, чем коэффициентов

Если

$$n + 1 > m + 1,$$

то данных больше, чем неизвестных коэффициентов.

Это основной случай метода наименьших квадратов.

Тогда обычно нельзя подобрать Q_m , проходящую через все точки сразу, поэтому минимизируют сумму квадратов отклонений:

$$\sum_{i=0}^n (f_i - Q_m(x_i))^2 \rightarrow \min.$$

Именно эта ситуация чаще всего возникает при обработке экспериментальных данных.

10 Вывод нормальных уравнений

Рассмотрим дискретный случай.

Пусть

$$Q_m(x) = \sum_{j=0}^m a_j \varphi_j(x).$$

Нужно минимизировать

$$S(a_0, \dots, a_m) = \sum_{i=0}^n \left(f_i - \sum_{j=0}^m a_j \varphi_j(x_i) \right)^2.$$

Это функция от $m + 1$ переменных:

$$a_0, a_1, \dots, a_m.$$

Чтобы найти минимум, используем необходимое условие экстремума:

$$\frac{\partial S}{\partial a_k} = 0, \quad k = 0, 1, \dots, m.$$

Вычислим частную производную:

$$\frac{\partial S}{\partial a_k} = 2 \sum_{i=0}^n \left(f_i - \sum_{j=0}^m a_j \varphi_j(x_i) \right) (-\varphi_k(x_i)).$$

Приравниваем к нулю:

$$-2 \sum_{i=0}^n \left(f_i - \sum_{j=0}^m a_j \varphi_j(x_i) \right) \varphi_k(x_i) = 0.$$

Делим на -2 :

$$\sum_{i=0}^n \left(f_i - \sum_{j=0}^m a_j \varphi_j(x_i) \right) \varphi_k(x_i) = 0.$$

Раскрываем:

$$\sum_{i=0}^n f_i \varphi_k(x_i) - \sum_{j=0}^m a_j \sum_{i=0}^n \varphi_j(x_i) \varphi_k(x_i) = 0.$$

Переносим вторую часть вправо:

$$\sum_{j=0}^m a_j \sum_{i=0}^n \varphi_j(x_i) \varphi_k(x_i) = \sum_{i=0}^n f_i \varphi_k(x_i).$$

Получаем систему нормальных уравнений:

$\sum_{j=0}^m a_j \langle \varphi_j, \varphi_k \rangle = \langle f, \varphi_k \rangle, \quad k = 0, 1, \dots, m.$

Здесь в дискретном случае

$$\langle \varphi_j, \varphi_k \rangle = \sum_{i=0}^n \varphi_j(x_i) \varphi_k(x_i),$$

а

$$\langle f, \varphi_k \rangle = \sum_{i=0}^n f_i \varphi_k(x_i).$$

11 Матричная форма нормальных уравнений

Система нормальных уравнений имеет вид

$$Ga = b.$$

Здесь

$$a = \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_m \end{pmatrix},$$

матрица G называется матрицей Грама:

$$G = \begin{pmatrix} \langle \varphi_0, \varphi_0 \rangle & \langle \varphi_1, \varphi_0 \rangle & \cdots & \langle \varphi_m, \varphi_0 \rangle \\ \langle \varphi_0, \varphi_1 \rangle & \langle \varphi_1, \varphi_1 \rangle & \cdots & \langle \varphi_m, \varphi_1 \rangle \\ \vdots & \vdots & \ddots & \vdots \\ \langle \varphi_0, \varphi_m \rangle & \langle \varphi_1, \varphi_m \rangle & \cdots & \langle \varphi_m, \varphi_m \rangle \end{pmatrix}.$$

Правая часть:

$$b = \begin{pmatrix} \langle f, \varphi_0 \rangle \\ \langle f, \varphi_1 \rangle \\ \vdots \\ \langle f, \varphi_m \rangle \end{pmatrix}.$$

Если функции

$$\varphi_0, \dots, \varphi_m$$

линейно независимы на заданных узлах, то матрица Грама невырождена, и система имеет единственное решение.

12 Частный случай: многочлен степени m

Пусть

$$\varphi_j(x) = x^j, \quad j = 0, 1, \dots, m.$$

Тогда

$$Q_m(x) = a_0 + a_1 x + \cdots + a_m x^m.$$

Нормальные уравнения принимают вид

$$\sum_{j=0}^m a_j \sum_{i=0}^n x_i^{j+k} = \sum_{i=0}^n f_i x_i^k, \quad k = 0, 1, \dots, m.$$

То есть система:

$$\begin{pmatrix} \sum 1 & \sum x_i & \sum x_i^2 & \dots & \sum x_i^m \\ \sum x_i & \sum x_i^2 & \sum x_i^3 & \dots & \sum x_i^{m+1} \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^4 & \dots & \sum x_i^{m+2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum x_i^m & \sum x_i^{m+1} & \sum x_i^{m+2} & \dots & \sum x_i^{2m} \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \\ a_2 \\ \vdots \\ a_m \end{pmatrix} = \begin{pmatrix} \sum f_i \\ \sum f_i x_i \\ \sum f_i x_i^2 \\ \vdots \\ \sum f_i x_i^m \end{pmatrix}.$$

Все суммы здесь берутся по

$$i = 0, 1, \dots, n.$$

Так как

$$\sum_{i=0}^n 1 = n + 1,$$

первый элемент матрицы равен числу наблюдений.

13 Аппроксимация прямой

Самый простой и важный случай — приближение данных прямой:

$$Q_1(x) = a_0 + a_1 x.$$

Тогда нужно найти a_0 и a_1 , минимизируя

$$S(a_0, a_1) = \sum_{i=0}^n (f_i - a_0 - a_1 x_i)^2.$$

Нормальные уравнения:

$$\begin{cases} a_0(n+1) + a_1 \sum x_i = \sum f_i, \\ a_0 \sum x_i + a_1 \sum x_i^2 = \sum f_i x_i. \end{cases}$$

В матричном виде:

$$\begin{pmatrix} n+1 & \sum x_i \\ \sum x_i & \sum x_i^2 \end{pmatrix} \begin{pmatrix} a_0 \\ a_1 \end{pmatrix} = \begin{pmatrix} \sum f_i \\ \sum f_i x_i \end{pmatrix}.$$

После решения этой системы получаем прямую наилучшего среднеквадратичного приближения.

14 Влияние степени многочлена

Важно понимать, что не всегда нужно брать многочлен большой степени. Если степень t слишком большая, то:

- система нормальных уравнений становится больше;
- коэффициенты могут стать очень чувствительными к малым изменениям исходных данных;
- аппроксимирующий многочлен может начать сильно колебаться;
- небольшое округление данных может сильно изменить результат.

Поэтому на практике часто берут многочлен небольшой степени, который хорошо описывает основную тенденцию данных.

Слишком высокая степень многочлена может ухудшить устойчивость аппроксимации.

15 Интерполяция или метод наименьших квадратов

Интерполяция хороша, если данные точные и нужно пройти через все узлы.

Метод наименьших квадратов лучше подходит, если данные зашумлены или являются результатами измерений.

Интерполяция	Метод наименьших квадратов
Проходит через все заданные точки	Не обязан проходить через все точки
Хороша для точных данных	Хорош для зашумлённых данных
Может сильно колебаться при большом числе узлов	Описывает общую тенденцию
Ошибка в узлах равна нулю	Минимизируется сумма квадратов ошибок

16 Весовой метод наименьших квадратов

Иногда разным точкам данных доверяют по-разному. Например:

- в некоторых точках измерение было сделано точнее;
- прибор после прогрева стал работать лучше;
- в некоторых точках измерения повторялись несколько раз и дали близкие значения;
- некоторые точки, наоборот, выглядят менее надёжными.

В таком случае вводят весовые коэффициенты

$$p_0, p_1, \dots, p_n,$$

где

$$p_i > 0.$$

Чем больше p_i , тем больше мы доверяем точке x_i .

16.1 Функционал с весами

Вместо обычной суммы квадратов минимизируют взвешенную сумму:

$$S(a_0, \dots, a_m) = \sum_{i=0}^n p_i (f_i - Q_m(x_i))^2.$$

Если точке доверяют больше, ей дают больший вес.

Если точке доверяют меньше, ей дают меньший вес.

16.2 Взвешенное скалярное произведение

Весовой метод можно понимать как метод наименьших квадратов с другим скалярным произведением:

$$\langle u, v \rangle_p = \sum_{i=0}^n p_i u(x_i) v(x_i).$$

Тогда нормальные уравнения принимают вид

$$\sum_{j=0}^m a_j \sum_{i=0}^n p_i \varphi_j(x_i) \varphi_k(x_i) = \sum_{i=0}^n p_i f_i \varphi_k(x_i), \quad k = 0, 1, \dots, m.$$

17 Геометрический смысл метода

Метод наименьших квадратов можно понимать как ортогональную проекцию.

Пусть есть пространство функций, а в нём подпространство, натянутое на функции

$$\varphi_0, \varphi_1, \dots, \varphi_m.$$

Мы ищем такую функцию

$$Q_m \in \text{span}(\varphi_0, \dots, \varphi_m),$$

которая ближе всего к f в смысле выбранного скалярного произведения.

Условие минимума означает, что ошибка

$$r = f - Q_m$$

ортогональна всем базисным функциям:

$$\langle f - Q_m, \varphi_k \rangle = 0, \quad k = 0, 1, \dots, m.$$

Именно из этих условий и получаются нормальные уравнения.

18 Мини-шпаргалка

Естественный кубический сплайн

Граничные условия:

$$S''(x_0) = 0, \quad S''(x_n) = 0.$$

Интерполяция

$$Q(x_i) = f_i.$$

Интерполяционный многочлен проходит через все заданные точки.

Метод наименьших квадратов

$$S = \sum_{i=0}^n (f_i - Q_m(x_i))^2 \rightarrow \min.$$

Общий вид аппроксимации

$$Q_m(x) = \sum_{j=0}^m a_j \varphi_j(x).$$

Нормальные уравнения

$$\sum_{j=0}^m a_j \langle \varphi_j, \varphi_k \rangle = \langle f, \varphi_k \rangle, \quad k = 0, \dots, m.$$

Дискретное скалярное произведение

$$\langle u, v \rangle = \sum_{i=0}^n u(x_i) v(x_i).$$

Непрерывное скалярное произведение

$$\langle u, v \rangle = \int_a^b u(x) v(x) dx.$$

Многочленный случай

Если

$$Q_m(x) = a_0 + a_1x + \cdots + a_mx^m,$$

то

$$\sum_{j=0}^m a_j \sum_{i=0}^n x_i^{j+k} = \sum_{i=0}^n f_i x_i^k, \quad k = 0, \dots, m.$$

Прямая наименьших квадратов

$$Q_1(x) = a_0 + a_1x.$$

$$\begin{cases} a_0(n+1) + a_1 \sum x_i = \sum f_i, \\ a_0 \sum x_i + a_1 \sum x_i^2 = \sum f_i x_i. \end{cases}$$

Весовой метод

$$S = \sum_{i=0}^n p_i (f_i - Q_m(x_i))^2 \rightarrow \min.$$

$$\langle u, v \rangle_p = \sum_{i=0}^n p_i u(x_i) v(x_i).$$

19 Главное, что нужно запомнить

1. В естественном кубическом сплайне на концах обнуляется вторая производная:

$$S''(x_0) = S''(x_n) = 0.$$

2. Интерполяция проходит через все точки, а метод наименьших квадратов описывает общую тенденцию данных.
3. Метод наименьших квадратов нужен, когда данные зашумлены или получены с погрешностями.
4. В дискретном случае минимизируется сумма:

$$\sum_{i=0}^n (f_i - Q_m(x_i))^2.$$

5. Аппроксимирующую функцию ищут в виде:

$$Q_m(x) = a_0\varphi_0(x) + \cdots + a_m\varphi_m(x).$$

6. Коэффициенты $a_0, \dots, a_m$ находятся из нормальных уравнений:

$$\sum_{j=0}^m a_j \langle \varphi_j, \varphi_k \rangle = \langle f, \varphi_k \rangle.$$

7. Для многочленного базиса $\varphi_j(x) = x^j$ получается система через суммы степеней x_i .

8. Если приближаем прямой, то нужно решить систему из двух уравнений:

$$\begin{cases} a_0(n+1) + a_1 \sum x_i = \sum f_i, \\ a_0 \sum x_i + a_1 \sum x_i^2 = \sum f_i x_i. \end{cases}$$

9. Чем выше степень многочлена, тем сильнее может проявляться чувствительность к ошибкам исходных данных.

10. Если разным точкам доверяют по-разному, используют весовой метод наименьших квадратов.