

Конспект по ЧМА

Сингулярное разложение матрицы

Содержание

1	Зачем вводить сингулярные числа	3
2	Связь матриц $A^T A$ и AA^T	3
3	Определение сингулярных чисел	4
4	Сингулярные числа как обобщение собственных чисел	4
5	Сингулярное разложение матрицы	5
5.1	Матрица U	6
5.2	Матрица V	6
5.3	Матрица Σ	6
6	Размеры матриц в SVD	6
6.1	Случай $m > n$	7
6.2	Случай $m < n$	7
7	Пример SVD для матрицы 2×3	7
7.1	Нахождение матрицы U	8
7.2	Матрица Σ	9
7.3	Нахождение матрицы V	9
8	Почему не всегда хорошо искать SVD через $A^T A$	10
9	Более устойчивый способ построения SVD	10
9.1	Первый этап: приведение к двухдиагональной форме	11
9.2	Второй этап: диагонализация двухдиагональной матрицы	11
10	Применения SVD	12
11	Ранг матрицы через SVD	12
12	Определитель через SVD	12
13	Число обусловленности	13
14	Решение однородной системы $Ax = 0$	14

15	Решение неоднородной системы $Ax = b$	15
15.1	Случай 1. Система совместна	16
15.2	Случай 2. Система несовместна	16
16	Псевдорешение	16
17	Сжатие информации через SVD	17
18	Геометрический смысл SVD	18
19	Сводная таблица	20
20	Мини-шпаргалка	21
21	Главное, что нужно запомнить	22

1 Зачем вводить сингулярные числа

До этого мы уже работали с понятием собственных чисел и собственных векторов. Однако собственные числа напрямую определены только для квадратных матриц.

Если матрица прямоугольная, например

$$A \in \mathbb{R}^{m \times n},$$

то говорить о собственных числах самой матрицы A в обычном смысле нельзя, потому что она отображает пространства разной размерности:

$$A : \mathbb{R}^n \rightarrow \mathbb{R}^m.$$

Но можно построить две квадратные матрицы:

$$A^T A \in \mathbb{R}^{n \times n},$$

и

$$A A^T \in \mathbb{R}^{m \times m}.$$

Обе эти матрицы являются:

- квадратными;
- симметричными;
- неотрицательно определёнными.

Следовательно, их собственные числа вещественные и неотрицательные. Именно через собственные числа этих произведений и определяются сингулярные числа.

2 Связь матриц $A^T A$ и $A A^T$

Пусть

$$A \in \mathbb{R}^{m \times n}.$$

Рассмотрим две матрицы:

$$A^T A$$

и

$$A A^T.$$

Их размеры различаются:

$$A^T A \in \mathbb{R}^{n \times n},$$

$$A A^T \in \mathbb{R}^{m \times m}.$$

При этом у матриц $A^T A$ и $A A^T$ совпадают все ненулевые собственные числа.

Например, если $m < n$, то матрица $A A^T$ имеет размер $m \times m$, а матрица $A^T A$ имеет размер $n \times n$. В таком случае у $A^T A$ может быть больше нулевых собственных чисел,

но ненулевые собственные числа будут совпадать с ненулевыми собственными числами матрицы AA^T .

Иначе говоря, матрицы

$$A^T A \quad \text{и} \quad AA^T$$

имеют одинаковую ненулевую часть спектра.

3 Определение сингулярных чисел

Пусть λ_i — собственные числа матрицы

$$A^T A.$$

Так как $A^T A$ симметрична и неотрицательно определена, то

$$\lambda_i \geq 0.$$

Сингулярные числа матрицы A определяются как

$$\sigma_i = \sqrt{\lambda_i}$$

То есть сингулярное число — это корень из собственного числа матрицы $A^T A$.

Аналогично можно брать собственные числа матрицы AA^T . Ненулевые сингулярные числа получатся теми же самыми.

Обычно сингулярные числа располагают в порядке невозрастания:

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0.$$

Если учитывать также нулевые сингулярные числа, можно писать:

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_p \geq 0,$$

где

$$p = \min(m, n).$$

Важно:

$$\boxed{\text{сингулярные числа всегда неотрицательны.}}$$

Они могут быть равны нулю.

4 Сингулярные числа как обобщение собственных чисел

Собственные числа хорошо работают для квадратных матриц, но для прямоугольных матриц их напрямую нет.

Сингулярные числа можно понимать как обобщение идеи собственных чисел на прямоугольные матрицы.

Рассмотрим важный частный случай.

Пусть матрица A квадратная и симметричная:

$$A = A^T.$$

Тогда

$$A^T A = A^2.$$

Если λ_i — собственные числа матрицы A , то собственные числа матрицы A^2 равны

$$\lambda_i^2.$$

Значит, сингулярные числа равны

$$\sigma_i = \sqrt{\lambda_i^2} = |\lambda_i|.$$

Получаем важное замечание:

если A — квадратная симметричная матрица, то $\sigma_i = |\lambda_i(A)|$.

То есть для симметричных матриц сингулярные числа совпадают с модулями собственных чисел.

Для произвольной квадратной матрицы это утверждение не обязано быть верным.

5 Сингулярное разложение матрицы

Для любой вещественной матрицы

$$A \in \mathbb{R}^{m \times n}$$

существует представление вида

$A = U \Sigma V^T$

Это представление называется **сингулярным разложением матрицы**, или **SVD**.
Здесь:

$$U \in \mathbb{R}^{m \times m}$$

— ортогональная матрица;

$$V \in \mathbb{R}^{n \times n}$$

— ортогональная матрица;

$$\Sigma \in \mathbb{R}^{m \times n}$$

— прямоугольная диагональная матрица.

Ортогональность означает:

$$U^T U = I, \quad V^T V = I.$$

Матрица Σ имеет вид:

$$\Sigma = \begin{pmatrix} \sigma_1 & 0 & 0 & \dots \\ 0 & \sigma_2 & 0 & \dots \\ 0 & 0 & \sigma_3 & \dots \\ \vdots & \vdots & \vdots & \ddots \end{pmatrix}.$$

Если матрица A прямоугольная, то Σ тоже прямоугольная.

5.1 Матрица U

Матрица U имеет вид

$$U = (u_1, u_2, \dots, u_m).$$

Её столбцы — это нормированные собственные векторы матрицы

$$AA^T.$$

То есть столбцы U образуют ортонормированный базис из собственных векторов матрицы AA^T .

5.2 Матрица V

Матрица V имеет вид

$$V = (v_1, v_2, \dots, v_n).$$

Её столбцы — это нормированные собственные векторы матрицы

$$A^T A.$$

5.3 Матрица Σ

Матрица Σ содержит сингулярные числа:

$$\sigma_i = \sqrt{\lambda_i}.$$

Обычно они записываются по диагонали в порядке невозрастания:

$$\sigma_1 \geq \sigma_2 \geq \dots \geq 0.$$

6 Размеры матриц в SVD

Если

$$A \in \mathbb{R}^{m \times n},$$

то полное SVD имеет вид:

$$A = U \Sigma V^T,$$

где

$$U \in \mathbb{R}^{m \times m},$$

$$\Sigma \in \mathbb{R}^{m \times n},$$

$$V^T \in \mathbb{R}^{n \times n}.$$

Проверим размеры:

$$(m \times m)(m \times n)(n \times n) = m \times n.$$

То есть размеры согласованы.

6.1 Случай $m > n$

Если $m > n$, то Σ имеет больше строк, чем столбцов:

$$\Sigma = \begin{pmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_n \\ 0 & 0 & \dots & 0 \\ \vdots & \vdots & \dots & \vdots \end{pmatrix}.$$

То есть снизу добавляются нулевые строки.

6.2 Случай $m < n$

Если $m < n$, то Σ имеет больше столбцов, чем строк:

$$\Sigma = \begin{pmatrix} \sigma_1 & 0 & \dots & 0 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \dots & \vdots \\ 0 & 0 & \dots & \sigma_m & 0 & \dots & 0 \end{pmatrix}.$$

То есть справа добавляются нулевые столбцы.

7 Пример SVD для матрицы 2×3

Рассмотрим матрицу

$$A = \begin{pmatrix} 1 & -1 & 0 \\ 0 & 1 & -1 \end{pmatrix}.$$

Тогда

$$A^T = \begin{pmatrix} 1 & 0 \\ -1 & 1 \\ 0 & -1 \end{pmatrix}.$$

Сначала удобно посчитать меньшую матрицу:

$$AA^T.$$

Получаем:

$$AA^T = \begin{pmatrix} 1 & -1 & 0 \\ 0 & 1 & -1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ -1 & 1 \\ 0 & -1 \end{pmatrix} = \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix}.$$

Найдём собственные числа этой матрицы.

$$\det(AA^T - \lambda I) = \begin{vmatrix} 2 - \lambda & -1 \\ -1 & 2 - \lambda \end{vmatrix} = (2 - \lambda)^2 - 1.$$

$$(2 - \lambda)^2 - 1 = 0.$$

$$2 - \lambda = \pm 1.$$

Отсюда

$$\lambda_1 = 3, \quad \lambda_2 = 1.$$

Следовательно, сингулярные числа:

$$\sigma_1 = \sqrt{3}, \quad \sigma_2 = 1.$$

7.1 Нахождение матрицы U

Для $\lambda_1 = 3$:

$$AA^T - 3I = \begin{pmatrix} -1 & -1 \\ -1 & -1 \end{pmatrix}.$$

Можно взять собственный вектор

$$\begin{pmatrix} -1 \\ 1 \end{pmatrix}.$$

Нормируем его:

$$u_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 \\ 1 \end{pmatrix}.$$

Для $\lambda_2 = 1$:

$$AA^T - I = \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix}.$$

Можно взять собственный вектор

$$\begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

Нормируем:

$$u_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

Тогда

$$U = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 & 1 \\ 1 & 1 \end{pmatrix}.$$

7.2 Матрица Σ

Так как A имеет размер 2×3 , то

$$\Sigma \in \mathbb{R}^{2 \times 3}.$$

Получаем:

$$\Sigma = \begin{pmatrix} \sqrt{3} & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix}.$$

7.3 Нахождение матрицы V

Теперь найдём V . Для этого рассмотрим

$$A^T A.$$

Получаем:

$$A^T A = \begin{pmatrix} 1 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 1 \end{pmatrix}.$$

Собственные числа:

$$\lambda_1 = 3, \quad \lambda_2 = 1, \quad \lambda_3 = 0.$$

Соответствующие нормированные собственные векторы можно взять такими:

$$v_1 = \frac{1}{\sqrt{6}} \begin{pmatrix} -1 \\ 2 \\ -1 \end{pmatrix},$$

$$v_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix},$$

$$v_3 = \frac{1}{\sqrt{3}} \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}.$$

Тогда

$$V = \begin{pmatrix} -\frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ \frac{2}{\sqrt{6}} & 0 & \frac{1}{\sqrt{3}} \\ -\frac{1}{\sqrt{6}} & -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \end{pmatrix}.$$

Итоговое сингулярное разложение имеет вид:

$$\boxed{A = U \Sigma V^T.}$$

То есть

$$\begin{pmatrix} 1 & -1 & 0 \\ 0 & 1 & -1 \end{pmatrix} = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} \sqrt{3} & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix} V^T.$$

8 Почему не всегда хорошо искать SVD через $A^T A$

Формально SVD можно построить через собственные числа и собственные векторы матриц

$$A^T A$$

и

$$A A^T.$$

Но численно это не всегда хорошо.

Проблема в том, что при вычислении $A^T A$ маленькие числа фактически возводятся в квадрат.

Например, если в матрице есть очень маленький параметр

$$\delta \ll 1,$$

то при переходе к $A^T A$ могут появиться величины порядка

$$\delta^2.$$

Если δ и так очень мало, то δ^2 может стать настолько маленьким, что компьютер воспримет это как ноль.

Из-за этого:

- маленькое сингулярное число может потеряться;
- ранг матрицы может быть посчитан неправильно;
- система, которая имела единственное решение, может быть воспринята как система с бесконечным числом решений;
- решение может стать численно неустойчивым.

Главная проблема:

формирование $A^T A$ ухудшает численную устойчивость.

Фактически при таком подходе маленькие сингулярные числа становятся ещё меньше, поскольку происходит возведение в квадрат.

9 Более устойчивый способ построения SVD

На практике SVD обычно не строят напрямую через $A^T A$.

Вместо этого применяют более устойчивые алгоритмы.

Общая идея состоит из двух этапов.

9.1 Первый этап: приведение к двухдиагональной форме

Исходную матрицу A приводят к двухдиагональной матрице B .

Двухдиагональная матрица — это матрица, у которой ненулевые элементы находятся только:

- на главной диагонали;
- на одной соседней диагонали.

Например:

$$B = \begin{pmatrix} \alpha_1 & \beta_1 & 0 & 0 \\ 0 & \alpha_2 & \beta_2 & 0 \\ 0 & 0 & \alpha_3 & \beta_3 \\ 0 & 0 & 0 & \alpha_4 \end{pmatrix}.$$

Для такого приведения используют ортогональные преобразования, например преобразования Хаусхолдера.

Идея записывается так:

$$B = U_1^T A V_1,$$

где U_1 и V_1 — ортогональные матрицы.

Тогда

$$A = U_1 B V_1^T.$$

9.2 Второй этап: диагонализация двухдиагональной матрицы

После этого двухдиагональную матрицу B приводят к диагональному виду:

$$B = \tilde{U} \Sigma \tilde{V}^T.$$

Для этого используют модификации QR-алгоритма.

Тогда

$$A = U_1 B V_1^T$$

превращается в

$$A = U_1 \tilde{U} \Sigma \tilde{V}^T V_1^T.$$

Сгруппируем множители:

$$U = U_1 \tilde{U},$$

$$V = V_1 \tilde{V}.$$

Получаем

$$\boxed{A = U \Sigma V^T.}$$

Такой подход устойчивее, потому что он не требует напрямую строить $A^T A$, а значит не усиливает проблему маленьких сингулярных чисел через возведение в квадрат.

10 Применения SVD

Сингулярное разложение используется во многих задачах. Основные применения:

1. нахождение ранга матрицы;
2. вычисление определителя;
3. вычисление числа обусловленности;
4. решение систем линейных уравнений;
5. нахождение псевдорешений несовместных систем;
6. сжатие информации, например изображений.

11 Ранг матрицы через SVD

Если известны сингулярные числа матрицы

$$\sigma_1, \sigma_2, \dots, \sigma_p,$$

то ранг матрицы равен количеству ненулевых сингулярных чисел:

$$\text{rank } A = \#\{i : \sigma_i \neq 0\}.$$

Например, если

$$\sigma_1 > 0, \quad \sigma_2 > 0, \quad \sigma_3 = 0,$$

то

$$\text{rank } A = 2.$$

На практике вместо строгого сравнения с нулём часто используют некоторый порог ε :

$$\sigma_i < \varepsilon.$$

Такие сингулярные числа считают численно нулевыми.

12 Определитель через SVD

Для квадратной матрицы

$$A \in \mathbb{R}^{n \times n}$$

из SVD имеем:

$$A = U \Sigma V^T.$$

Тогда

$$\det A = \det U \cdot \det \Sigma \cdot \det V^T.$$

Так как U и V ортогональные, то

$$|\det U| = 1, \quad |\det V| = 1.$$

Поэтому

$$|\det A| = |\det \Sigma|.$$

А определитель диагональной матрицы равен произведению диагональных элементов:

$$|\det A| = \sigma_1 \sigma_2 \cdots \sigma_n.$$

Итого:

$$|\det A| = \prod_{i=1}^n \sigma_i.$$

Если хотя бы одно сингулярное число равно нулю, то

$$\det A = 0.$$

13 Число обусловленности

Число обусловленности показывает, насколько сильно ошибка во входных данных может повлиять на результат.

Для нормы 2 число обусловленности выражается через сингулярные числа:

$$\text{cond}_2(A) = \frac{\sigma_{\max}}{\sigma_{\min}}$$

Если сингулярные числа упорядочены так:

$$\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0,$$

то

$$\text{cond}_2(A) = \frac{\sigma_1}{\sigma_r}.$$

Здесь:

- σ_1 — наибольшее сингулярное число;
- σ_r — наименьшее ненулевое сингулярное число.

Если σ_r очень маленькое, то число обусловленности очень большое.

Это означает, что система плохо обусловлена: маленькая ошибка в данных может привести к большой ошибке в решении.

14 Решение однородной системы $Ax = 0$

Рассмотрим систему

$$Ax = 0.$$

Пусть

$$A = U\Sigma V^T.$$

Тогда

$$U\Sigma V^T x = 0.$$

Так как U ортогональная, умножим слева на U^T :

$$\Sigma V^T x = 0.$$

Обозначим

$$y = V^T x.$$

Тогда система превращается в

$$\Sigma y = 0.$$

Пусть ранг матрицы равен r . Тогда первые r сингулярных чисел ненулевые:

$$\sigma_1, \dots, \sigma_r > 0,$$

а остальные равны нулю.

Система имеет вид:

$$\sigma_1 y_1 = 0,$$

$$\sigma_2 y_2 = 0,$$

...

$$\sigma_r y_r = 0.$$

Так как

$$\sigma_i \neq 0,$$

получаем:

$$y_1 = y_2 = \dots = y_r = 0.$$

Оставшиеся компоненты y , соответствующие нулевым сингулярным числам, могут быть любыми:

$$y = \begin{pmatrix} 0 \\ \vdots \\ 0 \\ c_{r+1} \\ \vdots \\ c_n \end{pmatrix}.$$

Так как

$$y = V^T x,$$

то

$$x = Vy.$$

Следовательно, общее решение:

$$x = c_{r+1}v_{r+1} + c_{r+2}v_{r+2} + \dots + c_nv_n.$$

То есть ядро матрицы A натянуто на столбцы матрицы V , соответствующие нулевым сингулярным числам:

$$\text{Ker } A = \text{span}\{v_{r+1}, \dots, v_n\}.$$

15 Решение неоднородной системы $Ax = b$

Теперь рассмотрим систему

$$Ax = b.$$

Подставим SVD:

$$U\Sigma V^T x = b.$$

Умножим слева на U^T :

$$\Sigma V^T x = U^T b.$$

Обозначим:

$$y = V^T x,$$

$$z = U^T b.$$

Тогда система превращается в простую систему:

$$\Sigma y = z.$$

Она записывается по координатам так:

$$\sigma_1 y_1 = z_1,$$

$$\sigma_2 y_2 = z_2,$$

...

$$\sigma_r y_r = z_r.$$

Отсюда:

$$y_i = \frac{z_i}{\sigma_i}, \quad i = 1, \dots, r.$$

Дальше возможны разные случаи.

15.1 Случай 1. Система совместна

Если все компоненты z , соответствующие нулевым строкам Σ , равны нулю, то система совместна.

То есть должно быть:

$$z_{r+1} = z_{r+2} = \dots = z_m = 0.$$

Тогда решение существует.

Если при этом нулевых сингулярных чисел нет, решение единственное.

Если нулевые сингулярные числа есть, решение не единственное, потому что часть переменных y остаётся свободной.

Общее решение находится по формуле

$$x = Vy.$$

15.2 Случай 2. Система несовместна

Если хотя бы одна из компонент

$$z_{r+1}, \dots, z_m$$

не равна нулю, то система

$$Ax = b$$

не имеет точного решения.

Тогда можно искать не точное решение, а псевдорешение.

16 Псевдорешение

Если система несовместна, то ищут такой вектор x , который минимизирует ошибку:

$$\|Ax - b\|.$$

То есть решают задачу:

$$\boxed{\|Ax - b\| \rightarrow \min.}$$

Такой вектор называется псевдорешением или решением в смысле наименьших квадратов.

Через SVD оно находится с помощью псевдообратной матрицы.

Если

$$A = U\Sigma V^T,$$

то псевдообратная матрица имеет вид:

$$A^+ = V\Sigma^+U^T.$$

Здесь Σ^+ получается из Σ так:

- ненулевые сингулярные числа заменяются на обратные:

$$\sigma_i \mapsto \frac{1}{\sigma_i};$$

- нули остаются нулями;
- матрица меняет размер на транспонированный.

Тогда псевдорешение:

$$x = A^+b.$$

То есть

$$x = V\Sigma^+U^Tb.$$

17 Сжатие информации через SVD

Ещё одно важное применение SVD — сжатие информации.

Например, изображение можно представить как матрицу.

Для чёрно-белого изображения каждый пиксель задаётся числом, например от 0 до 255:

- 0 — чёрный;
- 255 — белый;
- промежуточные значения — оттенки серого.

Тогда изображение можно представить как матрицу:

$$A = \begin{pmatrix} a_{11} & a_{12} & \dots \\ a_{21} & a_{22} & \dots \\ \vdots & \vdots & \ddots \end{pmatrix}.$$

Разложим её:

$$A = U\Sigma V^T.$$

Это можно переписать как сумму матриц ранга 1:

$$A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \dots + \sigma_r u_r v_r^T.$$

Так как сингулярные числа упорядочены по убыванию:

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r,$$

первые слагаемые несут больше всего информации, а последние обычно меньше влияют на изображение.

Поэтому можно оставить только первые k слагаемых:

$$A_k = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \dots + \sigma_k u_k v_k^T.$$

Тогда

$$A_k \approx A.$$

При этом хранить нужно не всю матрицу A , а только:

- первые k сингулярных чисел;
- первые k столбцов U ;
- первые k столбцов V .

Так получается сжатие.

Чем меньше k , тем сильнее сжатие, но хуже качество изображения.

Чем больше k , тем качество лучше, но сжатие слабее.

18 Геометрический смысл SVD

Сингулярное разложение показывает, что любую матрицу можно представить как композицию трёх действий:

$$A = U \Sigma V^T.$$

Геометрически это можно понимать так:

1. V^T — поворот или отражение в исходном пространстве;
2. Σ — растяжение или сжатие вдоль координатных осей;
3. U — поворот или отражение в новом пространстве.

То есть действие матрицы A можно представить как

$$\text{поворот} \longrightarrow \text{растяжение} \longrightarrow \text{поворот}.$$

Сингулярные числа показывают, во сколько раз матрица растягивает пространство по главным направлениям.

19 Сводная таблица

Понятие	Формула / смысл
Сингулярные числа	$\sigma_i = \sqrt{\lambda_i(A^T A)}$
SVD	$A = U \Sigma V^T$
Матрица U	Столбцы U — нормированные собственные векторы матрицы AA^T .
Матрица V	Столбцы V — нормированные собственные векторы матрицы $A^T A$.
Матрица Σ	На диагонали стоят сингулярные числа: $\sigma_1 \geq \sigma_2 \geq \dots \geq 0.$
Ранг	$\text{rank } A = \#\{i : \sigma_i \neq 0\}$
Определитель	Для квадратной матрицы: $ \det A = \prod_i \sigma_i$
Число обусловленности	$\text{cond}_2(A) = \frac{\sigma_{\max}}{\sigma_{\min}}$
Ядро	Если $\sigma_{r+1} = \dots = \sigma_n = 0$, то $\text{Ker } A = \text{span}\{v_{r+1}, \dots, v_n\}.$
Псевдорешение	$x = A^+ b = V \Sigma^+ U^T b$
Сжатие	$A_k = \sum_{i=1}^k \sigma_i u_i v_i^T$

20 Мини-шпаргалка

Определение сингулярных чисел

$$\sigma_i = \sqrt{\lambda_i(A^T A)}$$

Сингулярное разложение

$$A = U \Sigma V^T$$

где

$$U^T U = I, \quad V^T V = I.$$

Ранг

$$\text{rank } A = \#\{\sigma_i \neq 0\}.$$

Определитель

Для квадратной матрицы:

$$|\det A| = \prod_i \sigma_i.$$

Число обусловленности

$$\text{cond}_2(A) = \frac{\sigma_{\max}}{\sigma_{\min}}.$$

Ядро

Если

$$\sigma_{r+1} = \dots = \sigma_n = 0,$$

то

$$\text{Ker } A = \text{span}\{v_{r+1}, \dots, v_n\}.$$

Псевдорешение

$$x = A^+ b = V \Sigma^+ U^T b.$$

Сжатие

$$A_k = \sum_{i=1}^k \sigma_i u_i v_i^T$$

Это приближение матрицы A матрицей ранга k .

21 Главное, что нужно запомнить

1. Сингулярные числа определяются через собственные числа матрицы $A^T A$:

$$\sigma_i = \sqrt{\lambda_i(A^T A)}.$$

2. Любая вещественная матрица имеет SVD:

$$A = U\Sigma V^T.$$

3. Сингулярные числа всегда неотрицательны.
4. Если матрица квадратная и симметричная, то сингулярные числа равны модулям собственных чисел:

$$\sigma_i = |\lambda_i|.$$

5. Ранг матрицы равен количеству ненулевых сингулярных чисел.
6. Маленькие сингулярные числа отвечают за плохую обусловленность.
7. Через SVD удобно решать системы линейных уравнений и находить псевдорешения.
8. Через SVD можно сжимать изображения и другие данные, отбрасывая слагаемые с маленькими сингулярными числами.